

学校代码：10259
学 号：196141104
密 级：公开

上海应用技术大学

硕士学位论文

题 目：____基于深度学习的 UWB 定位算法研究____

英文题目：____Research on UWB positioning
method based on deep learning____

学 科：____控制科学与工程____

学 院：____计算机科学与信息工程学院____

研究方向：____室内定位____

姓 名：____叶晓桐____

指导教师：____张裕____

2022 年 5 月 6 日

学位论文版权使用授权书

本学位论文作者完全了解学校有关保留、使用学位论文的规定，同意学位论文保留并向国家有关部门或机构送交论文的复印件和电子版。允许论文被查阅和借阅。本人授权上海应用技术大学可以将本学位论文的全部内容或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存和汇编本学位论文。

保 密 ____ 年 ☐

本学位论文属于 不保密 ☒

（必须在相应处打√，否则按不保密处理）

学位论文作者签名：叶晓桐

2022 年 5 月 6 日

指导教师签名：张裕

2022 年 5 月 6 日

学位论文作者声明

本人郑重声明：所呈交的学位论文，是本人在导师的指导下，独立进行研究工作所取得的成果。除文中已注明引用的内容外，本论文不包含任何其他个人或集体已经公开发表或撰写过的作品成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

本声明的法律责任由本人承担。

学位论文作者签名：叶晓桐

2022 年 5 月 6 日

基于深度学习的 UWB 定位算法研究

摘要

近年来,因为商场导购、工业生产、跟踪搜寻等领域的急切需求,人们对室内定位服务的精度和可靠性的要求越来越高。超宽带(Ultra Wide Band, UWB)定位以其高精度和高稳定性的优势迅速发展普及,同时深度神经网络因其较强的非线性映射能力成为现阶段备受研究人员青睐的热门。本文以深度学习方法解决 UWB 定位问题。主要完成的工作如下:

1、本文提出一种自编码器预处理的神经网络结构,解决室内定位中因多径效应等原因引起的数据缺失、定位精度不高的问题。该模型首先利用深度自编码器来对缺失数据以及受多径效应影响的数据进行弥补和调整,然后再用 BP 神经网络来建立映射关系。实验证明该方法定位性能较好。

2、本文提出一种基于注意力机制的 UWB 定位算法。由 SENet 注意力模块与卷积神经网络构建一个深度学习网络 SE-CNN。SENet 注意力模块降低了受到动态干扰因素影响的定位数据权重,再利用卷积神经网络(CNN)确定定位数据与目标位置的非线性关系。该定位模型能够减少动态环境下多径效应与非视距带来的定位误差。实验结果表明,该算法在定位精度方面优于其他算法,且具有较好的稳定性。

关键词: UWB; TDOA; 深度学习; 注意力机制

Research on UWB positioning method based on deep learning

abstract

In recent years, due to the urgent needs of shopping guides in shopping malls, industrial production, tracking and searching, etc., people have higher and higher requirements for the accuracy and reliability of indoor positioning services. UWB positioning has developed and popularized rapidly due to its advantages of high precision and high stability. At the same time, deep neural network has become a current research hotspot because of its strong nonlinear mapping ability. This paper studies the UWB positioning method based on deep learning. The main completed work is as follows:

1. This paper proposes a neural network structure preprocessed by an autoencoder to solve the problems of missing data and low positioning accuracy caused by multipath effects and other reasons in indoor positioning. The model firstly uses deep autoencoder to make up and adjust missing data and data affected by multipath effect, and then uses BP neural network to establish the mapping relationship. Experiments show that this method has better localization performance.
2. Aiming at the problem that multi-path effect and non-line-of-sight environment affect the accuracy of ultra-wideband (UWB) indoor positioning, this paper proposes a UWB positioning algorithm based on attention mechanism. A deep learning network SE-CNN is constructed by SENet attention module and convolutional neural network. The SENet attention module reduces the weight of the localization data affected by dynamic interference factors, and then uses a convolutional neural network (CNN) to determine the nonlinear relationship between the localization data and the target position. The positioning model can reduce the positioning error caused by multipath effect and non-line-of-sight in dynamic environment. The experimental results show that the algorithm is superior to other algorithms in terms of positioning accuracy and has better stability.

Keywords: UWB; TDOA; Deep Learning; Attention Mechanism

目录

第 1 章 绪论.....	5
1.1 研究背景及意义.....	5
1.2 研究现状.....	6
1.2.1 UWB 技术起源与发展.....	7
1.2.2 UWB 传统方法研究现状.....	8
1.2.3 UWB 机器学习方法研究现状.....	8
1.3 创新点.....	9
1.4 章节内容安排.....	10
第 2 章 超宽带技术概述.....	11
2.1 UWB 定位技术概述.....	11
2.2 传统 UWB 定位算法.....	13
2.2.1 基于到达角的算法 AOA.....	13
2.2.2 基于信号强度的算法 RSSI.....	14
2.2.3 基于到达时间的算法 TOA.....	15
2.2.4 基于到达时间差的算法 TDOA.....	16
2.3 定位精度影响因素.....	17
2.3.1 非视距传播.....	17
2.3.2 多径效应.....	17
2.3.3 时钟同步.....	18
2.4 本章小结.....	18
第 3 章 基于深度学习的 UWB 定位算法.....	19
3.1 引言.....	19
3.2 深度学习模型概述.....	19
3.2.1 自编码器.....	19
3.2.2 BP 神经网络.....	20
3.2.3 卷积神经网络.....	21
3.3 定位结果评价指标.....	21
3.4 基于深度自编码器的 UWB 定位算法.....	22
3.4.1 深度自编码器的框架结构.....	22
3.4.2 实验环境.....	23
3.4.3 网络训练过程.....	25
3.4.4 结果与分析.....	26
3.5 本章小结.....	29
第 4 章 基于注意力机制的 UWB 定位算法.....	30
4.1 引言.....	30
4.2 注意力机制概述.....	30
4.2.1 通道注意力机制.....	30
4.2.2 空间注意力模型.....	31

4.2.3 结合通道和空间的注意力模型.....	31
4.3 注意力机制网络模型.....	31
4.4 数据准备.....	33
4.5 定位过程.....	34
4.6 结果分析.....	35
4.7 本章小结.....	37
第 5 章 结论与展望.....	39
5.1 结论.....	39
5.2 展望.....	39
参考文献.....	41
致 谢.....	46
攻读学位期间发表的学术论文.....	47

第 1 章 绪论

1.1 研究背景及意义

近年来,人们对商场导购、工业生产、跟踪搜寻、路经规划等领域的需求愈加迫切,对位置服务的精确度,可靠性和响应时间的要求也越来越高。

在室外定位领域中广泛应用的主要有两种技术手段——一是基于运营商的基站定位技术^[1]。该技术受天气、位置的影响较小,但定位区域需要有三个以上基站部署并且得到的定位结果误差较大,误差距离可达百米;二是基于导航卫星信号的定位,也即 GNSS 定位^[2]。美国 GPS 和中国北斗卫星等信号全球各地均可接收,可以通过接收导航卫星信号完成误差在 10 米左右的精确度较高的定位,但同时也是因为接收的卫星信号所以受到天气的影响较大,且定位时目标上空需无遮挡才可以接收到卫星信号。

室内定位与室外定位大不相同。室内的空间远远小于室外,所以需要定位精度较高的技术,基于运营商的基站定位技术因误差较大难以适用于室内定位。而卫星信号因建筑物阻隔无法到达室内,所以基于导航卫星信号的定位技术同样无法用于室内定位。

可现如今,人们工作和生活的绝大部分时间都在室内。无论是快递智能分拣还是商场、餐厅机器人服务引领,都与定位技术联系紧密,因此该技术的发展和研究也一直备受关注。

不像室外定位技术中导航卫星信号定位市场占有率较大,室内定位多种技术表现出齐头并进的趋势。没有哪一种室内定位技术可以普适于各种复杂的室内定位场景中。

目前比较成熟的室内定位技术大致归为三类,第一类是根据信号强弱变化衰减的方法,例如有 Wi-fi 指纹定位、蓝牙定位等。前者的优势在于覆盖面广,几乎没有硬件设备开销,然而指纹数据采集过程繁琐,一旦环境变化还需更新指纹库,否则会有较大误差^[3];蓝牙定位技术的特点在于短距离、功耗低、方便部署,而争议则是蓝牙信号强弱只可估计距离,不可辨别方位,在最近的蓝牙 5.1 中引入到达角和出发角对上述问题做出改善^[4]。第二类是基于到达时间的定位方法,例如有 UWB 定位、超声波定位等。UWB 定位和超声波定位都可以得到高精度的定位结果。UWB 定位抗干扰能力显著,但布置基站需要较大成本^[5、6]。超声波定位受到诸如多径效应和开普勒效应影响较大,同时也需要较高的硬件设施部署成本^[7]。三是基于航迹推算的方法,例如有利用惯导传感器的定位。惯性导航传感器定位的方法一般不会单独应用于室内定位中,这是由惯导定位本身属性决定的,因为惯导定位系统在不断的位置推导过程中,误差不断累积,且系统没有自我纠正误差的能力,所以时间越久,惯导系统推导的位置误差越大^[8]。下(表 1.1)中列举了上述技术的部分属性,方便比较。

表 1.1 部分室内定位技术属性比较表

Tab.1.1 Attribute comparison table of some indoor positioning technologies

技术	范围 (m)	精度 (m)	带宽 (MHz)	频率 (MHz)
Wi-fi 定位	50-100	5-10	40-160	$2.4 \times 10^3 - 5 \times 10^3$
蓝牙定位	0.1-10	1-2	80	2.4×10^3
UWB 定位	50-100	$10 \times 10^{-2} - 15 \times 10^{-2}$	>500	$3 \times 10^3 - 10.5 \times 10^3$
超声波定位	30-100	$5 \times 10^{-2} - 20 \times 10^{-2}$	5	1-30

经过以上论述可知，这三大种室内定位技术都存在不可回避的劣势和自身存在的优势，可以根据所需定位范围的大小、定位需求的精度，以及室内场景的复杂程度，抗干扰强弱、定位时延大小等层面考虑，利用合适的室内定位方法。出于现实中想要把多个定位技术优势发挥在一个定位系统中的考虑，目前研究中把两个甚至多个定位技术融合到一个定位系统中的研究方向十分火热。想要提高融合技术的各方面性能，归根到底还是得拆开来分别研究单个技术的发展难点和创新方向。

UWB 定位技术虽然硬件设备成本较高，但它传输速度快，抗干扰性强、定位精度高等优势在众多室内定位技术中非常突出^[9]。

因为 UWB 定位技术是基于到达时间的定位技术，所以对系统时钟同步的要求很高。做到时钟同步后，接下来就要考虑定位算法。基于 UWB 定位的传统方法以及传统方法的改进与融合都期望把误差计算出来，再在得到的结果的基础上进行弥补，但是多径效应和阴影效应等导致的误差很难建模，并且容易随环境改变，还需重新实验计算误差。在本文中，深度学习代替传统建模量化，利用神经网络的映射能力在定位数据与目标位置之间建立更加准确的非线性关系，提高定位系统的精度。

1.2 研究现状

1.2.1 UWB 技术起源与发展

UWB 技术最早开始于二十世纪六十年代以前，属于脉冲通信，它利用超宽基带脉冲进行信号传输^[10]。UWB 技术最开始为军方所用，主要用于雷达或定位等领域中。也正因为 UWB 技术这一时期只掌握在军方手中，所以技术的发展缓慢。2002 年，美国制定 UWB 设备民用规定，其中明确了 UWB 系统定义同时也放开了对民用 UWB 技术和设备的限制^[11]。2005 年我国唐恩科技开始着手于 UWB 技术的研究。2006 年，日本开放 UWB 频段。2007 年，美国的丰塔纳根据 UWB 的测距特性对 UWB 系统进行分类，分为入侵检测，精确测距和防撞三类，同年 UWB 芯片设备的生产市值达 14 亿美元^[12]。Fernando Ramirez Mireles 分析了在有加性高斯白噪声(AWGN)、多用户干扰(MUI)和具有视距(LOS)的密集多径效应(DME)的情况下的信号干扰(SIR)退化和非视距(NLOS)^[13]。

接下来的十几年中，国内外 UWB 技术领域的专家学者们就 UWB 信道模型探索、干扰的抑制和分离、定位方式的探索、定位系统准确度的研究等方面逐步深入展开。

2008 年,我国学者关于 NLOS 问题找到初步解决办法,从这一年起,国内外室内定位领域的众多学者开始研究抑制 NLOS 的算法。2009 年,Amir Nasri 等人研究受 UWB 干扰影响的比特交织编码调制正交频分复用系统性能,计算了当超宽带干扰被建模为附加高斯噪声时的误码率,得出 BICM-OFDM 系统的误码率强依赖于 UWB 格式和 OFDM 子载波间距^[14]。2010 年,我国学者刘、广等人设计一种小型的信号接收器,采用集成了阶跃恢复二极管和一对肖特基二极管的采样鉴相器来对雷达的 UWB 信号进行采样,推动接收器小型化发展^[15]。同年,吉林大学研究出基于到达方向和到达角的协同定位方法,该方法通过融合两种定位方法划定更准确定位区域的方式在一定程度上减少单一方法导致的较大偏差,但适用范围有局限性。2012 年,Yalcin Sadi 等人研究了速率控制的超宽带无线网络中,在流量需求、传输功率和信噪比约束条件下,时延最小化的最优调度问题,提出了利用基于排除区域和效用最大化的列生成方法(EXUM-CGM)来快速地解决该问题^[16]。2013 年,熊、张等人提出了一种降低复值自适应陷波滤波器干扰的办法,该方案利用信号的实质性相关差异,并通过估计相应的中心频率来去除带有噪声的 UWB 信号中的窄带干扰(NBI)^[17]。2018, Brecht Hanssens 等人提出了一种基于三角测量法的 UWB 信道探测定位框架模型,利用出发角、到达角、到达时延、估计方差等传播路径的几何特性建立模型^[18]。2019, zhu 等人在进行辅助惯导系统中 UWB 测距偏差补偿的研究时,没有使用机器学习的方法来识别、消除偏差,而是通过施密特-卡尔曼滤波器(SKF)来估计误差,并在 SKF 之上提出了基于约束 sigma 点的校正滤波提高系统精度^[19]。2020, Gao 等人发明了一种高压超宽带脉冲发生器,利用两个连续的梯形波将超宽带信号合成转移到数字域。该设计需要一个低损耗无源滤波器来满足超宽带频谱规则,增加一个功率放大器,将输出电压提高到电源电压限值以上^[20]。2021 年, Cao 等人提出了一种新颖的时分多址(TDMA)算法,该算法可以快速调度大型设备网络对 UWB 介质的使用,而不会在本地网络邻域发生冲突,并避免与隐藏终端发生冲突,同时能够最大限度地提高网络使用率^[21]。

值得关注的是著名的 UWB 芯片公司 DecaWave,由它研发的 DW1000 芯片取得较大的成功,但因为价格偏高而不普及。

在过去的二十年中,各种各样的短距离无线服务的研究和实施出现了前所未有的增长。然而,多种短程通信技术的部署也造成了无线电频谱的过度使用。UWB 技术以为稀缺频谱提供可替换方案为宗旨,因为它可以与其他无线电技术共存并且产生最小干扰的特性。

UWB 技术的蓬勃发展也使得该技术的应用领域得到较大扩展,从刚起步时在军事领域的信息通信、雷达探测领域到现在的智能家居系统、智慧交通、智慧工厂、石油化工系统、智慧监狱系统等。UWB 技术及其衍生技术正在使人们的生活更快捷、更智慧。我们有理由相信 UWB 技术将在未来会有更耀眼的成绩。

1.2.2 UWB 传统方法研究现状

传统常用的 UWB 定位算法包括 Fang 算法、Taylor 算法以及 Chan 算法等。其中 Fang

算法^[22]不能利用冗余信息提高计算精度; Chan 算法^[23]的性能在非视距中显著下降; Taylor 算法^[24]初值的选择直接决定定位结果的优劣,所以目前基于传统算法改进和融合算法较多。文献[25]中将卡尔曼滤波与 Chan 算法结合起来,减少在不确定性因素影响下的定位误差,即在 Chan 算法得到估计值的基础上利用卡尔曼滤波算法再次对既得估计值进行再次估计,该方法能够在 Chan 算法的基础上小幅减少定位误差,但当 Chan 算法的估计值出现偏差时,再估计难以进行误差的校正弥补。文献[26]中利用 Chan 算法识别、降低非视距误差。该方法分为三步,第一步用 Chan 算法估算出待测运动物体的初始位置,在此基础上计算 TDOA 测量误差,第二步进行误差门限比较、非视距误差识别及降低,第三步再用 Chan 算法估算待测物体的精确位置信息。但该方法非视距识别和降低的效果不算理想,所以导致定位效果与单纯使用 Chan 算法相比提升并不明显。文献[27]提出了一种质心结合泰勒展开的定位算法。该方法首先用质心算法对待测物体进行大致上的定位估计,接着将估计值代入 Taylor 展开,进行精确度相对较高的再次定位,极大提高了已有数据的利用率。该方法提高了 Taylor 算法初值选取的优越性,减少定位过程中的设备投入、节约成本。文献[28]研究非视距情况下 CHAN-Taylor 算法的适用表现,提出首先对非视距误差运用中心极限定理完成消除和降低操作,然后分别利用 CHAN 算法和 CHAN-Taylor 算法得到目标位置,再进行加权后得出目标位置预测值。该算法对于权值的给定无法给出较为合理地解释,有待进一步探究。文献[29]对分布式基站以及时延处理进行了实地实验探究,对时延误差进行曲线拟合,再利用 Fang 算法对多 PRU 组网下的目标定位精度进行提升,该方法从误差来源角度进行误差的消减,对设备及部署有较高要求。

传统方法以及两种及以上传统方法的融合算法发展缓慢且艰辛,传统方法与机器学习融合的方法成为未来几年的发展方向。

1.2.3 UWB 机器学习方法研究现状

传统定位方法的计算方式使得定位精度的瓶颈难以突破,而近年来机器学习深度学习的蓬勃发展给 UWB 定位的突破提供了一条新思路。即将定位过程看成一个分类器分类的过程,或者通过建立神经网络模型来固化固定环境中的难以建模的误差,如非视距误差。最近几年,许多文献研究使用机器学习、神经网络等方法降低上述因素的影响^[30]。下面将对机器学习领域,重点在神经网络领域的研究进行阐述。

文献[31]提出了一种 NLOS 识别方法。该方法结合 Fisher 线性判别器和支持向量机(SVM)对信道脉冲响应进行分类,在光线昏暗的房间以及地下室、走廊的场景下表现出较好的性能,然而分类定位的精确度往往难以突破。文献[32]提出了基于 k 近邻(KNN)的 NLOS 检测方法运用在“居家养老系统”中,该算法对训练样本进行建模,找到识别准确率最高的 K 值,在样本数量较少的情况下精确度也能达到系统需求。文献[33]设计并实现了一种基于 UWB 的 LSTM-WKNN 混合定位模型。该模型首先利用 LSTM 模型预测未来时刻的 TDOA 值,然后用预测数据来修正实际的 UWB 测量数据,接着将修改后的 TDOA 数据传递给 WKNN 算法,用该算法得到目标位置。文献[34]把 TDOA 数据作为研究对象,

利用一个 3 层的误差反向回传神经网络 (BP) 结构训练实验数据, 期望提升视距环境下定位的精确度, 但 BP 神经网络的固有弊端, 容易得到局部极小值以及收敛缓慢、甚至不收敛的问题没有得到解决。文献[35]探寻降低非视距情况下定位准确度出现偏差的办法。其包含两步, 第一, 利用非视距情况下定位数据特征搭建立卷积神经网络 (CNN), 目的是建立由非视距定位数据到视距定位数据的映射关系。第二, 利用扩展卡尔曼滤波算法得到定位信息。但该方法在处理位置突变的情形时扩展卡尔曼滤波效果不佳。文献[36]为减弱多径效应及非视距的影响, 提出用免疫算法对 BP 进行寻优, 该方法在定位准确度方面表现较好, 但网络的输入是 3 个 TDOA 数据, 导致算法实施的范围只能是一个房间内部。文献[37]中使用低辐射脉冲无线电超宽带 (IR-UWB) 雷达, 利用卷积神经网络 (CNN) 计算人数。由于人类运动的尺度大小、叠加情况, 同时信号也因为距离和角度等原因受到影响, 这两方面的原因都给每个范围内的目标检测带来挑战。该方法从接收到的数据中提取出多尺度范围时间地图, 并进一步使用 CNN 对人数进行分类。通过目标在检测区域的密度和模式分布的形式来完成人数计数。此外, 目前很多实验仿真占比比较大, 无法得知在现实情况下的性能表现, 另外在一些实地场景中将环境因素做静态处理, 而在现实应用中不能有效处理移动的人或物等动态干扰因素带来的定位误差问题。

1.3 创新点

针对室内定位 UWB 技术存在因非视距、多径效应等影响造成的定位结果稳定性差, 精确度低的问题, 本文将研究重点聚焦于 UWB 的 TDOA 数据上, 利用适宜的模型建立基站坐标、TDOA 值, 到目标位置的映射关系。现将本文的创新方法总结如下:

(1) 提出一种基于深度自编码器的 UWB 定位模型, 首先利用深度自编码器来对缺失数据以及受多径效应影响的数据进行弥补和调整, 然后再用 BP 神经网络来建立从定位数据到目标数据的映射关系。利用该模型, 系统的定位稳定性和精确度有改善。

(2) 提出一种适用于有动态搅扰因素环境下的基于注意力机制的 UWB 定位模型。该模型是由 SENet 注意力模块和卷积神经网络 (CNN) 构建组成, 命名为 SE-CNN。SENet 注意力模块的作用为降低了受到动态因素搅扰情况下的 TDOA 和基站位置的权重, 再利用 CNN 来建立从位置数据到目标数据的非线性映射关系。该定位模型能够有效降低环境中动态因素的干扰带来的非视距及多径效应的误差。并且在部署的实验环境中验证了该模型在误差的减少和稳定性的提高方面表现出色。

1.4 章节内容安排

本文第一章为绪论内容, 主要论述了本文所研究技术的背景、研究该技术的现实意义, 以及 UWB 技术的由来与发展进程。接着通过举例文献的方式阐述 UWB 技术发展至今, 它在传统技术方法和机器学习方法两个领域各自的发展现状。随后, 在前人研究开拓的基础上提出本文的创新思想。在本章结尾, 给出全文的总体脉络安排。

第二章是超宽带技术概述部分。主要包括三块内容——UWB 定位技术概述、UWB 定位算法以及定位精度影响因素。定位技术概述主要简介 UWB 技术应用领域, 定位算法详细阐述基于到达角的算法 AOA, 基于信号强度的算法 RSSI, 基于到达时间的算法 TOA,

基于到达时间差的算法 TDOA。在本章的最后列举出定位精度影响因素，重点阐释了时钟同步、多径效应和非视距传播这三大类因素对定位准确度的影响。

第三章为基于深度学习的 UWB 定位算法。首先介绍常用的、也在本文中直接或间接使用的深度学习模型，包括自编码器、BP 和 CNN。然后重点阐述提出的基于深度自编码器的 UWB 定位算法，介绍其框架结构，运用该算法的过程以及最后的结果对比分析。在本章的最后给出本文关于定位效果优劣判定的评价指标，本文主要利用两个指标——均方根误差和欧式距离。其中均方根误差在第三章基于深度自编码器的定位和第四章基于注意力机制的定位中用到，欧式距离在第四章基于注意力机制的定位中用到。

第四章是基于注意力机制的 UWB 定位算法。在本章开头简单介绍了三种注意力机制及其作用，然后系统性阐述整个基于注意力机制的 UWB 定位方法的实验过程，包括实验环境的介绍，数据的准备，网络模型的设计，实验数据在模型中的作用过程和最后的与其他网络模型定位结果的对比分析，通过实验验证了所设计模型在有动态搅扰环境下的良好性能。

第五章首先对全文内容和重点所做工作进行了简要总结，然后对于之后的研究实验作出一些计划，并列出三点进行说明。

第 2 章 超宽带技术概述

2.1 UWB 定位技术概述

UWB 的频率在 3.1-10.6GHz 之间，其带宽大；传输速率在每秒兆比特甚至千兆比特，传输速度较高；对其他无线电系统的干扰有较强的抵抗力，抗干扰能力强。

UWB 技术的种种优势让它在定位测距，信息通信及雷达探测等领域应用中表现突出。

在定位测距领域，UWB 测距是在通信过程中根据数据包到达时间来实现测距，而且可由距离完成定位，如（图 2.1）。因为基于 UWB 信号的定位技术能实现室内外的高精度定位，所以在军方和民用方面均有发展。例如大型商场导购、车辆间距测量、跟踪搜寻救援。




图 2.1 UWB 定位示意图

Fig.2.1 Schematic diagram of UWB positioning

在信息通信领域，因为 UWB 信号所占用的带宽较大，信道容量较大，但 UWB 信号因功率局限，传播距离往往不长。因此该技术应用于短距离、高速度的通信较多。例如 USB2.0 利用 UWB 技术实现无线传输，如（图 2.2）。另外，在无线个域网、智能交通和军事情报通信等领域，UWB 技术也因信息传输的高效性和抗截获能力有一定的应用。




图 2.2 UWB 技术实现 USB2.0

Fig.2.2 UWB technology realizes USB2.0

在雷达探测领域，UWB 信号不是利用载波来传输信息，而是利用基带窄脉冲，在这点上和雷达信号的传输有较大的相似性。并且，其穿透力极强，能够准确地辨认障碍物后的物体情况，如（图 2.3）。除此之外，UWB 的高精确度也是其优势之一。因此 UWB 技术可应用在雷达探测技术可以应用到的诸多领域中，并且可以达到较好的效果。

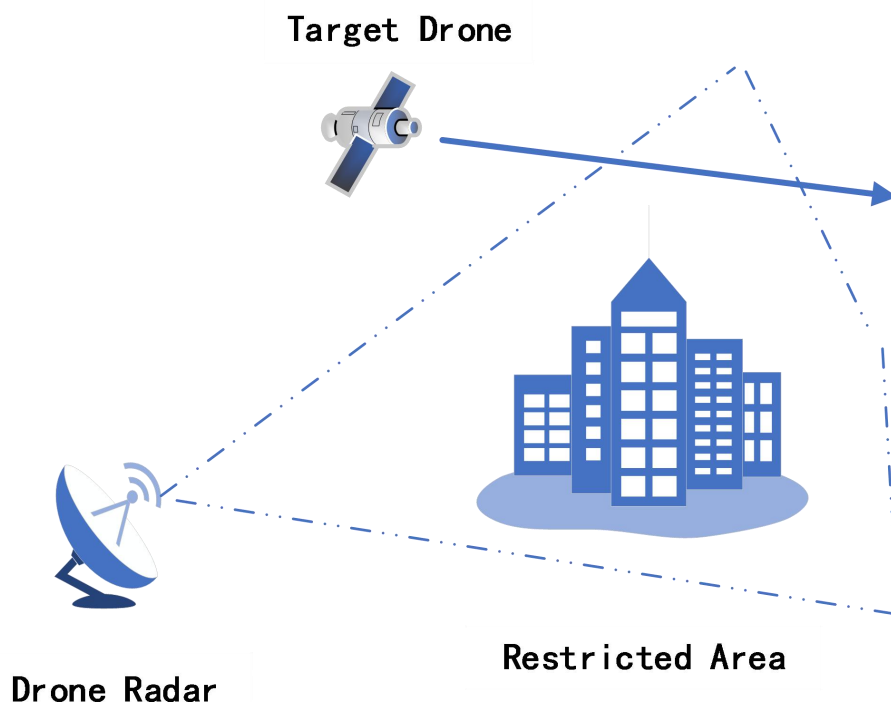


图 2.3 UWB 技术应用于雷达探测

Fig.2.3 UWB technology applied to radar detection

2.2 传统 UWB 定位算法

2.2.1 基于到达角的算法 AOA

基于到达角的算法（AOA）通过计算信号从目标到基站间的角度来确定目标的可能范围，最终完成定位^[38]。AOA 算法定位目标需要两个基站。两基站所在直线与基站和目

标之前形成四个夹角，规定两基站所在直线的正方向，测量目标和基站与正方向的两个夹角的度数，并列方程组计算目标的位置。如（图 2.4）所示。




图 2.4 AOA 算法原理示意图

Fig.2.4 Schematic diagram of the principle of AOA algorithm

如上图所示建立平面直角坐标系，两基站 BS1、BS2 位置固定不变，坐标已知，设为 (x_1, y_1) 、 (x_2, y_2) ，目标和基站 BS1 与两基站所在直线正方向的夹角设为 θ_1 ，目标和基站 BS2 与两基站所在直线正方向的夹角设为 θ_2 ，且 θ_1 、 θ_2 已知。目标标签坐标未知，设为 (x, y) 。根据以上条件可列出如下方程组(2-1)：

$$\begin{cases} \tan(\theta_1) = \frac{x - x_1}{y - y_1} \\ \tan(\theta_2) = \frac{x - x_2}{y - y_2} \end{cases} \quad (2-1)$$

两个方程，两个未知数，即可解出 x 、 y 的值。AOA 算法相比与其他算法所需基站数量最少。但也正因如此，角度测量时的小误差就可能造成计算结果大的偏差，在非视距或其他搅扰严重的情况下甚至无法测量到角度值。所以单纯双基站 AOA 定位能力不足，需要连同天线阵列一同布置才能有较好的效果，然而增设天线阵列不但增大硬件成本而且也让系统更加臃肿。所以 AOA 定位算法只有理论上的优越性，在实际情况下，几乎不会单独使用。

2.2.2 基于信号强度的算法 RSSI

基于信号强度的算法 RSSI 利用信号强度由发射地向远处逐渐递减的原理，在信号强弱模型和距离远近模型之间建立映射关系^[39]。归根到底，RSSI 算法也是一种模式识别。使用该算法首先要明确信号衰减模型，测量和计算信号功率值，然后建立距离与信号功率对应的关联关系，最后完成将信号强度到具体距离的转换。下面描述其关系。

设标签发射功率 P_t ，基站接收功率为 P_b ，标签发射信号增益为 G_t ，基站接收信号增益为 G_b ，路径损耗系数为 η ，在不同的室内室外环境中 η 的取值不同，可参考相关文献，更准确地确定 η 。由发射时的信号强度和接收时的信号强度来计算信号在传输过程中的衰弱，基站在距离标签 d 时的信号接收功率列式如下式(2-2)：

$$P_b(d) = P_t G_t G_b \left(\frac{\eta}{4\pi d} \right)^2 \quad (2-2)$$

传输损耗模型参考 IEEE 802.15.4a 标准可写作下式(2-3)：

$$P(d) = P_0 + 10\eta \log_{10}(d/d_0) + N \quad (2-3)$$

d_0 为标签与基站间的任意距离， P_0 表示距离 d_0 处的功率。 N 为方差为 σ^2 变量，该值与路径损耗系数具有一一对应关系。

基于信号强度的算法成本较低，部署容易，但是距离的远近与信号强度的关联关系的建立需要大量实验数据采集，当室内环境发生变化时需要再次测量采集，并且定位结果受多径效应等的影响，定位精确度不高。

2.2.3 基于到达时间的算法 TOA

基于到达时间的算法是目前室内 UWB 定位领域中使用相对较多的方法之一。该算法通过确定信号传输时间来确定距离。通过目标标签与三个基站之间的传输时间得到目标标签与三个基站间的距离，通过联立方程组即可解出目标标签所在位置坐标。因为 UWB 带宽宽度大，时间精度较高，所以该方法在定位精确度方面存在优势。

基于到达时间的算法具体可分为三个步骤。第一步获取传输时间，即获取目标标签到三个基站的传输时间。第二步时间转化为距离，第一步获取的时间乘上转换因子，转换因子为光在真空中传播速度 $3 \times 10^8 \text{ m/s}$ 得到目标标签到三个基站的距离。第三步根据几何原理列方程组求解坐标，理论上，以三个基站各自为圆心，第二步中所得的对应距离为半径，作出三个圆，三个圆的公共交点即为目标标签所在位置^[40]。

TOA 原理如（图 2.5）所示。




图 2.5 TOA 算法原理图

Fig.2.5 Schematic diagram of TOA algorithm

如上（图 2.5）所示，三个基站坐标分别设为 $BS_1(x_1, y_1)$ 、 $BS_2(x_2, y_2)$ 、 $BS_3(x_3, y_3)$ ，且三个坐标已知。目标标签未知，设为 (x, y) 。标签到三个基站的距离假设已求得，分别设为 d_1 、 d_2 、 d_3 。

根据上述条件可列方程组如下式(2-4)：

$$\begin{cases} (x_1 - x)^2 + (y_1 - y)^2 = d_1^2 \\ (x_2 - x)^2 + (y_2 - y)^2 = d_2^2 \\ (x_3 - x)^2 + (y_3 - y)^2 = d_3^2 \end{cases} \quad (2-4)$$

整理方程可解的 x 与 y 的值，也即得到目标标签的位置坐标。

基于到达时间的算法的误差成因包括基站与目标标签之间的时钟同步偏差、三个基站间的时钟同步偏差、从信号发射到接收中间的延迟或其他影响因素造成的干扰等。也正因如此，想要得到高精度的定位结果，对系统的时间同步提出了极高的要求，而现实的设备往往难以满足这一要求。

2.2.4 基于到达时间差的算法 TDOA

基于到达时间差的算法是在 TOA 基础上对系统时钟同步问题的思考和进一步解决该问题的尝试。由 2.2.3 部分可知 TOA 通过目标标签与三个基站之间的传输时间得到目标

标签与三个基站间的距离，对基站与目标标签间的时钟同步要求极高。TDOA 则是通过测量目标标签到各基站的时间差从而得到各自对应的距离差，再通过计算得到坐标。这里不用考虑目标标签与基站的时钟同步问题。时间差转换为距离差同 TOA 中时间转换为距离方法一样。得到距离差后，分别把任意两个基站当做焦点，对应距离差当做长轴，绘出两组双曲线，其交点即所求坐标^[41]。

由上可知 TDOA 至少需要 2 个距离差，所以定位至少也需要三个基站，且对这三个及以上的基站要求时钟同步。

TDOA 可分为三个过程。第一步，获取发送及接收时间，即获取目标标签信号发送时间及基站接收时间。第二步，得到时间差并转化为距离差，第一步获取的时间差乘上转换因子 $3 \times 10^8 \text{ m/s}$ 。得到目标标签到三个基站的距离差。第三步根据几何原理列方程组求解坐标，理论上，以基站 1、基站 2 和基站 1、基站 3 分别作为焦点，第二步中所得的对应距离差当做长轴，绘出两组双曲线，其交点即所求坐标。

TDOA 的原理如（图 2.6）所示：




图 2.6 TDOA 算法原理图

Fig.2.6 Schematic diagram of TDOA algorithm

如上（图 2.6）所示，三个基站坐标分别设为 $BS_1(x_1, y_1)$ 、 $BS_2(x_2, y_2)$ 、 $BS_3(x_3, y_3)$ ，且三个坐标已知，目标标签未知，设为 (x, y) ，标签信号到达基站 2 和基站 1 的距离差设为 d_{12} ，到达基站 3 和基站 1 的距离差设为 d_{13} ^[42]。

根据上述条件可列方程组(2-5)：

$$\begin{cases} \sqrt{(x_2 - x)^2 + (y_2 - y)^2} - \sqrt{(x_1 - x)^2 + (y_1 - y)^2} = d_{12} \\ \sqrt{(x_3 - x)^2 + (y_3 - y)^2} - \sqrt{(x_1 - x)^2 + (y_1 - y)^2} = d_{13} \end{cases} \quad (2-5)$$

整理方程可解的 x 与 y 的值，也即得到目标标签的位置坐标。

基于到达时间差的算法定位误差主要来源于三个基站间的时钟同步偏差、从信号发射到接收中间的延迟或其他影响因素干扰导致的信号减损等。TDOA 定位不要求基站与目标标签之间的时间同步，只要求三个基站间进行时间同步。然而相对于移动的目标标签而言，固定不动的基站间的时间同步在技术上的实现难度会低很多。

综上所述，TDOA 在基站时钟同步的情况下定位的精确度可以达到较理想的结果。TDOA 与 TOA 相比较，TOA 很难做到目标标签与基站间的时钟同步，所以定位结果存在固有偏差，TDOA 定位效果更佳。TDOA 与 AOA 相比，TDOA 实地运用的可实践性更强，不需要部署天线阵列，节约成本和人力。TDOA 与 RSSI 相比较，TDOA 不需要大量实验采集数据建立模型，当室内环境发生变化时也无需再次测量采集数据，具有更强的灵活性。因为 UWB 系统的时间精度较高，所以 TDOA 可以充分发挥其优势，实现高精度的定位。

2.3 定位精度影响因素

2.3.1 非视距传播

非视距 (NLOS) 传播是指 UWB 信号的发射和接收端之间有遮挡，致使接收端收到多个到达信号，且第一路径信号混合在分量信号中，难以区分，对 UWB 定位及测距系统精度造成较大影响^[43]。超宽带定位技术可以在无遮挡条件下也即视距情况下实现厘米级的精度标准。所以非视距传播的解决能够提升定位精确度和抗干扰能力。

TOA、TDOA 算法在视距条件下性能较好。然而在非视距下则不可避免地出现定位误差偏大的情况。为了 UWB 的定位精度得到进一步提高，亟需寻找消除或降低非视距误差的途径。现阶段消除或降低非视距误差的常用手段是给到达时间值的权重赋值。理论上，其他情况不变的情况下非视距条件下的到达时间应是大于视距条件下的到达时间，实践中证明确实如此。所以，在视距和非视距两种情况下，可以给到达时间值赋以各自不同的权重，以检测和减弱由非视距引起的定位误差。

2.3.2 多径效应

多径效应是由障碍物引起的信号发散现象，该现象使信号接收处无法正常收到第一路径信号^[44]。建筑所用钢筋、混凝土、水泥，以及木头、塑料、玻璃等不同材质对信号的发散以及互相搅扰作用，都会造成信号弥散和失真。在定位场景下，多径效应的存在会增加超宽带测距和定位的难度，带来定位误差，降低系统的稳定性。此外，由于多径效应的存在，几种普遍的定位算法，如 TOA、AOA、RSSI、TDOA 都会受到或多或少的影

建模多径效应和其他干扰的具体影响难题。

2.3.3 时钟同步

本文所用的是 TDOA 数据，与时间有关，所以时钟同步是其中一个影响因素。

通常，时钟漂移率由振荡器的硬件决定^[45]。然而，在现实生活中，所有硬件设备的振荡器都有或多或少的频率偏差，实验结果往往比理论推导要差很多。除此之外，频率偏差随着一些物理因素和其他因素发生改变。实验表明，即便时钟频率随时间变化，它依然可以用高精度、固定频谱的振荡器来表示。

时钟同步应要做到两点。一是时钟的变化率相同，二是各时钟没有偏移误差。具体来说，在一个网络系统中实现时钟同步，即将所有节点的时钟调节到同一时刻。可以把时钟同步的两个要点看作是几人一同跑步，如果想让几个人一直处于同一直线上，那么就要要求几个人必须在同一条直线上起跑，并且以同一速度匀速跑。同样的如果在时钟同步中，只关注起始的时间相同，而不关注时钟的漂移变化速度，通过时间积累时钟的同步错位将越来越大。当然，想要做到完全时钟同步几乎不可能实现，但偏移误差的变化又不可忽视，所以可以通过频繁强制时钟置于同一时刻来尽量减少误差积累，努力实现时钟同步。

超宽带定位系统中，时钟同步的方法主要有：第一，利用时间戳广播；第二，利用参考节点；第三，利用双向响应^[46]。随着硬件设施的发展，新的方法也渐渐涌现出来。比如在时钟同步问题不能妥善解决时可采用不用时钟同步的方法同样达到定位目的，本文的硬件设备无法实现双边信号的收发功能，因此不采取该方法。

结合硬件设施、定位需求、复杂程度等多方面思考和权衡之下，本文的实验选择利用同步包进行时钟同步。同步包同步方法如下：

(1) 确定主基站、从基站。

(2) 由主基站向从基站定时不间断地发送同步包，进行时钟同步校准。

为了方便计算，这里将从基站的 TOA 测量数据统一转化为主基站数据，再进行 TDOA 的计算。

2.4 本章小结

本章内容主要围绕 UWB 定位技术及其应用、UWB 定位算法，以及影响因素展开。

首先简单介绍了 UWB 技术在定位、测距、通信、雷达探索领域的应用情况和现状。接着详细阐述了 UWB 定位算法的四种常见算法，即 AOA、RSSI 以及 TOA 和 TDOA，并分析了各算法的特点，优势以及不足之处。综合比较之下选定了 TDOA 作为本文研究对象。最后列举了影响定位精度较大的三项影响因素——非视距传播、时钟同步以及多径效应。分别解释了产生原因说明了部分传统解决对策，以及论述了本文的解决办法对降低和消灭这些影响因素的有效性。

第 3 章 基于深度学习的 UWB 定位算法

3.1 引言

从第一和第二章的内容可以看出传统方法的发展缓慢且艰难,突破较为困难,因此很多专家学者将目光转向蓬勃发展的深度学习领域,希望能够借助深度学习为定位精度寻求突破。本章提出一种自编码器预处理的神经网络结构,解决室内定位中因多径效应等原因引起的数据缺失、定位精度不高的问题。该模型首先利用深度自编码器来对缺失数据以及受多径效应影响的数据进行弥补和调整,然后再用 BP 神经网络来建立映射关系,实验证明效果良好。

3.2 深度学习模型概述

人工神经网络是由人的生物信号经神经元细胞体及突触传递兴奋或者抑制这一过程中得到启发形成的结构^[47、48]。理论上,使用 3 层及以上的神经网络,在神经元数量足够多的情况下可以完成任意非线性函数的映射。神经网络的组成单元叫做神经元^[49]。通过调整神经元连接方式及每个神经元的参数使得整个神经网络达到解决某一问题最优的策略。

神经网络组成通常包括输入层、隐藏层、输出层。网络结构的深度越深它能够表示的函数复杂度越高。

本文主要使用到自编码器、BP 神经网络、卷积神经网络。接下来将简述上述网络结构。

3.2.1 自编码器

深度学习领域里,自编码器(autoencoder)属于无监督网络类型。它由编码器与解码器组建^[50],如(图 3.1)。其中,前者是从输入数据学习特征的过程,后者是从编码器提取特征重新构造数据的过程。从编码和解码的过程来看,该结构可以用于输入数据降维。提到数据降维难免会与主成分分析相比较,神经网络与主成分分析相比效果相对更好,因为神经网络能够提取出新的隐藏特征^[51]。也可以在经过训练后能尝试还原输入,作为强大的特征检测和提取器,也可以和一些监督模型结合使用,具有灵活性。

下面将阐述自编码器的特征。首先,自编码器具有数据相关性,也就是说输入自编码器的数据要和之前自编码器训练的数据具有相同或相似的意义和组织形式。其次,自编码器在压缩和重构过程之后最终得到的数据并非与原数据完全一致,这也就意味着它是有数据损失的。就这一点而言,可以与图片的有损压缩类比。第三,自编码器具有目标特定性,这意味着它可以自动学习特定类别的数据。




图 3.1 自编码器示意图

Fig.3.1 Autoencoder schematic

总结来说，自编码器能够学到数据的高效表示，可以通过编码降低输入数据维度实现降维，也可以尝试还原输入，作为强大的特征检测器。自编码器属于前馈网络，因此可以从深度结构中学习到较好的特征。

3.2.2 BP 神经网络

BP 神经网络是一种误差逆着传播方向的前馈型结构^[52]。它可以在没有映射方程的情况下，仅根据输入和输出内容自身完成复杂的映射过程。将模型的输出与真实值的差值作为反向传播的依据，根据链式法则反向调整每个神经元的权值等参数^[53]。每得到一个输出就会有一次反向调整，如此通过大量数据的训练调整，模型的输出与真实值的差值会在一个很小的范围内，训练停止，此时的模型能够对此类数据有较好的性能。下（图 3.2）为一个三层的 BP 示意图。




图 3.2 3 层 BP 神经网络示意图

Fig.3.2 Schematic diagram of 3-layer BP neural network

3.2.3 卷积神经网络

卷积神经网络（CNN）在符号识别、目标背景分离等图像处理领域有着优异的性能，也因此广泛应用于计算机视觉等领域^[54]。其结构包括卷积层、池化层以及全连接层^[55]，如（图 3.3）所示。通过卷积和池化的作用提取输入数据的特征，接着再利用全连接层完成结果输出。




图 3.3 CNN 示意图

Fig.3.3 Schematic diagram of CNN

CNN 的优势存在以下几点：

- 1、参数共享的设计极大降低了系统计算复杂度，局部感知极大地减少参数量，使得模型对庞大的数据集依然保持较强的处理水平^[56]。
- 2、深度挖掘和提取输入数据的内部联系，并对其作出良好表达。
- 3、特征选择由神经网络自动完成。只要对卷积核权重和偏置进行训练即可获得特征值。

CNN 的劣势存在以下几点：

- 1、对计算机的算力要求较高，因为需要训练的数据量较大，所以所需时间较长。
- 2、无法从数学和物理层面对其原理作出合理的推导和意义的诠释。

3.3 定位结果评价指标

定位算法性能的好坏需要选定一个或两个统一的指标进行衡量，这一指标最好能够以数值的形式量化定位精确度。在目前许多的定位研究中，通常选择利用均方误差和欧式距离来对定位系统的结果进行评估，本文也是选用主流的评价指标来进行算法优劣的判断。

1、均方根误差

均方根的计算并不复杂，它描述为根号下预测值与实际值之差的平方除上预测值数。它是预测与实际间差别的一种量化。均方误差小则表明预测或估计较精确，定位系统性能较好，反之则表明定位系统性能较差，定位精确度低^[57]。

在本文中，均方误差用来计算每次预测坐标与实际坐标的差距。预测的坐标是网络模型的输出，实际坐标由红外测量仪测得，因为该仪器精度很高，所以将测量得到的结果等同于真实位置坐标。

均方误差的计算方式如下(3-1)：

$$RMSE = \sqrt{\frac{\Delta d_1^2 + \Delta d_2^2 + \Delta d_3^2 + \cdots \Delta d_n^2}{n}} \quad (3-1)$$

上式中， Δd_i 意为第 i 次目标标签预测坐标与标签真实坐标之间的偏差，如下式(3-2)：

$$\Delta d_i = \sqrt{(x_i - x_{real})^2 + (y_i - y_{real})^2} \quad (3-2)$$

2、欧式距离

欧氏距离多用于计算两个点之间在真实空间中的真实距离，适用但不局限于二维、三维空间^[58]。

欧氏距离计算方式如下(3-3)：

$$D_{ED} = \sqrt{(x_1 - x_2)^2 + (y_1 - y_2)^2} \quad (3-3)$$

上式表示二维空间中两个点间的真实距离。因为其反应距离的真实性，所以通常作为距离方面的评价指标。

3.4 基于深度自编码器的 UWB 定位算法

3.4.1 深度自编码器的框架结构

首先将数据送入深度自编码器中进行预处理。深度自编码器对输入进行层层压缩、特征提取，将全部特征集中到输出层的 2 个神经元，解码器通过 2 个集中特征的神经元生成重构，还原编码器原始输入。输入是 16 个元素输出是 16 个元素，这个过程是个无监督学习过程。这个部分的作用是对多径效应和数据缺失有一定的弥补。编码器是 3 层的全连接神经网络，每层神经元的数量分别为 16，12，2，激活函数利用 $\tanh()$ 。解码器则相反，神经元数量为 2，12，16。其具体结构如（图 3.4）所示。

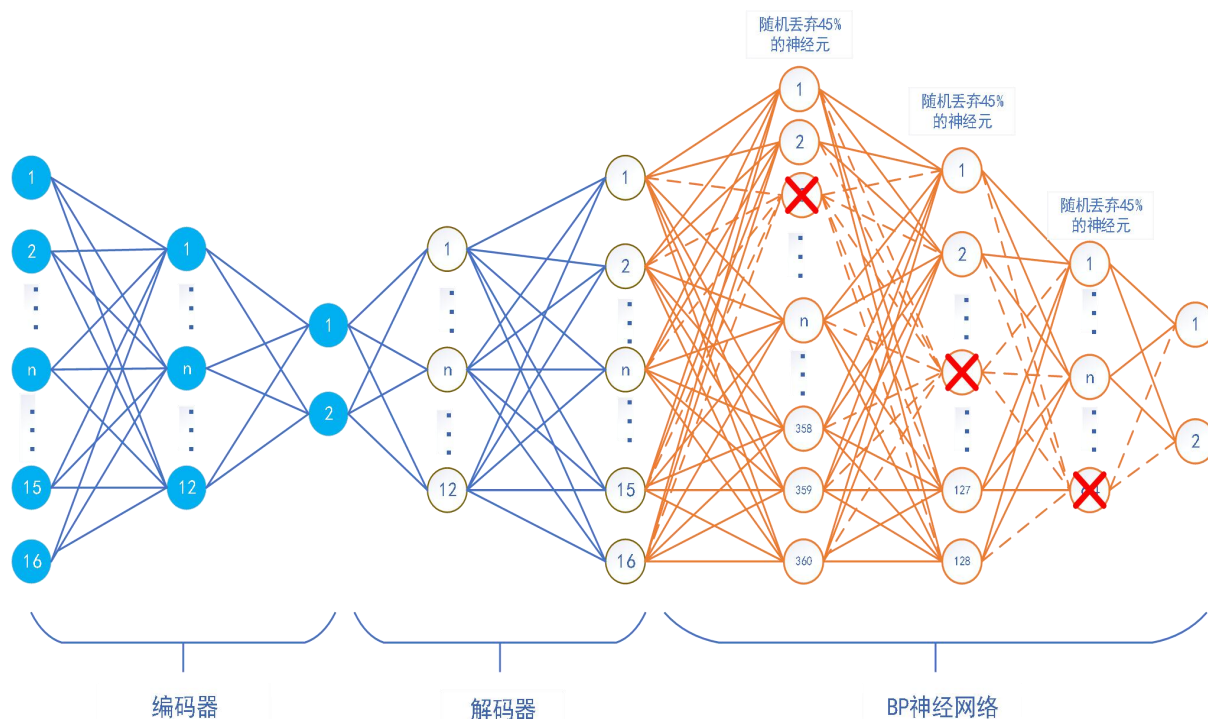


图 3.4 DAE-BP 示意图

Fig.3.4 Schematic diagram of DAE-BP

数据经过深度自编码器预处理之后将进入一个 5 层的 BP 神经网络中。各层神经元数量设置为 16, 360, 128, 64, 2, 为避免过拟合每层随机丢弃掉 45% 的神经元结点不做传输。数据训练将均方误差作为损失函数进行计算, 使用 Adam 进行寻优, 学习率为 0.001。本实验在两个神经网络结构的组合下进行训练。

3.4.2 实验环境

本实验在学校信息楼 4 楼的一间实验室完成, 该实验室结构简单, 但人员流动具有不确定性。定位系统设计如下 (图 3.5) 所示。

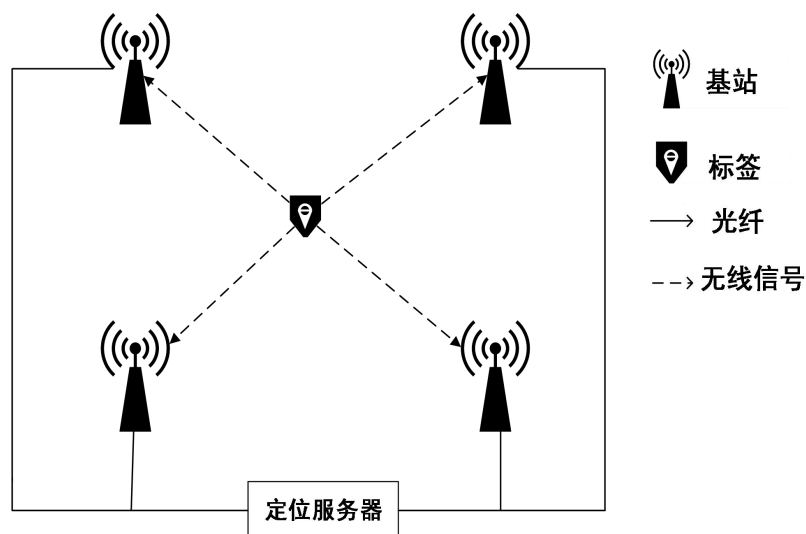


图 3.5 室内设备分布示意图

Fig.3.5 Schematic diagram of indoor equipment distribution

实验室长约 7 米、宽约 6 米，实验设备包括一台服务器，4 个基站，2 个标签，1 个支架。实验中所用的 4 个基站的位置坐标如下（表 3.1）所示。

表 3.1 基站坐标表

Tab.3.1 Base Station Coordinate Table

基站编号	X(m)	Y(m)	Z(m)	是否为主基站
1	22.301	3.554	2.868	否
2	15.240	3.554	2.868	否
3	21.904	7.730	2.909	是
4	15.381	7.730	2.868	否

服务器上安装定位软件，用于接收基站发送的数据；实验室四个角处布置 UWB 信号基站，四个基站通过光纤相连到定位服务器上，4 个基站中有 1 个主基站，3 个从基站；标签体积小可移动供电；支架用于支撑标签。标签通过支架固定在高度 1 米的位置，在实验室中定点进行数据测量。将得到的数据包中的时间戳转换成所需的 TDOA 值。标签的真实位置的坐标由红外测距仪测得，红外测距仪的测量误差小于 1cm。

标签的真实坐标部分数据呈现如下（表 3.2）

表 3.2 标签真实坐标表

Tab.3.2 Label real coordinate table

编号	X(m)	Y(m)	Z(m)
1	21.502	3.555	1
2	20.702	1.094	1
3	19.902	3.555	1
4	21.502	4.155	1
5	20.702	4.155	1
6	19.902	4.155	1
7	21.502	4.755	1
8	20.702	4.755	1
9	19.902	4.755	1
10	21.502	5.355	1

本实验定义了本地直角坐标系，标签及基站分布如（图 3.6）所示。基站部署在室内的四个角落，悬挂固定在房间顶部四角，分为主基站和从基站。根据室内面积大小，均匀规划标签测量点。长边每行 5 个测量点，短边每列 4 个测量点，共规划 20 个点进行标签定位数据采集。




图 3.6 基站、标签分布图

Fig.3.6 Base station and tag distribution map

实验室内部署 UWB 定位系统，基站发送到服务器端的数据经过转化得到 TDOA 值。实验时，将支架按照实现计划好的位置依次放置好，标签将会被固定到支架上，标签的发送数据频率约为 32Hz，每个标签连续测量 5 分钟，得到大约 10000 组数据，用得到的数据完成对比实验。目标标签的真实坐标由激光测距仪测量得到，本文使用均方误差和欧式距离作为性能优劣的评价指标，最终以测试中的均方误差以及欧氏距离的值来衡量各个算法的优劣。

3.4.3 网络训练过程

本文实验数据一组数据有 19 个元素，去掉标签高度不考虑剩下有 18 个元素。前 16 个元素为基站坐标和 TDOA 数据，第 17 和 18 个元素为标签的二维坐标。将归一化数据每组的前 16 个元素作为网络模型的输入，后两个元素作为网络模型的输出。因为输入元素为 16 个，所以自编码器输入层设置 16 个神经元，数据输入后先将 16 个神经元数据特征压缩到 12 个神经元当中，然后进一步压缩到 2 个神经元中，接着将 2 个神经元中的特征重构到下层 12 个神经元中，再到下层 16 个神经元中，得到的重构结果与原数据的差值反向传播调整神经元的权值等参数。使用自编码器是为学习输入数据的内部特征，以期在输入有部分缺失或因周围环境影响造成数据偏差的情况下模型仍能具有较稳定的性能。这一部分的训练结束后，将该部分的输出作为 5 层 BP 的输入，经过神经元结点数分别为 16 和 360 的两层，随机丢弃掉 45% 的神经元结点不传输数据避免过拟合，接着经过设置有 128 个神经元的第三层，和设置有 64 个神经元的第四层，同样这两层在传输时都随机丢弃掉 45% 的神经元结点，最后的输出层有两个神经元。均方误差作为损

失函数进行计算, 使用 Adam 进行寻优, 学习率为 0.001。损失函数计算误差, 反向传输给每个神经元结点调整权值等参数, 直到准备数据用尽得到平均误差值。

算法流程如下 (图 3.7) 所示。

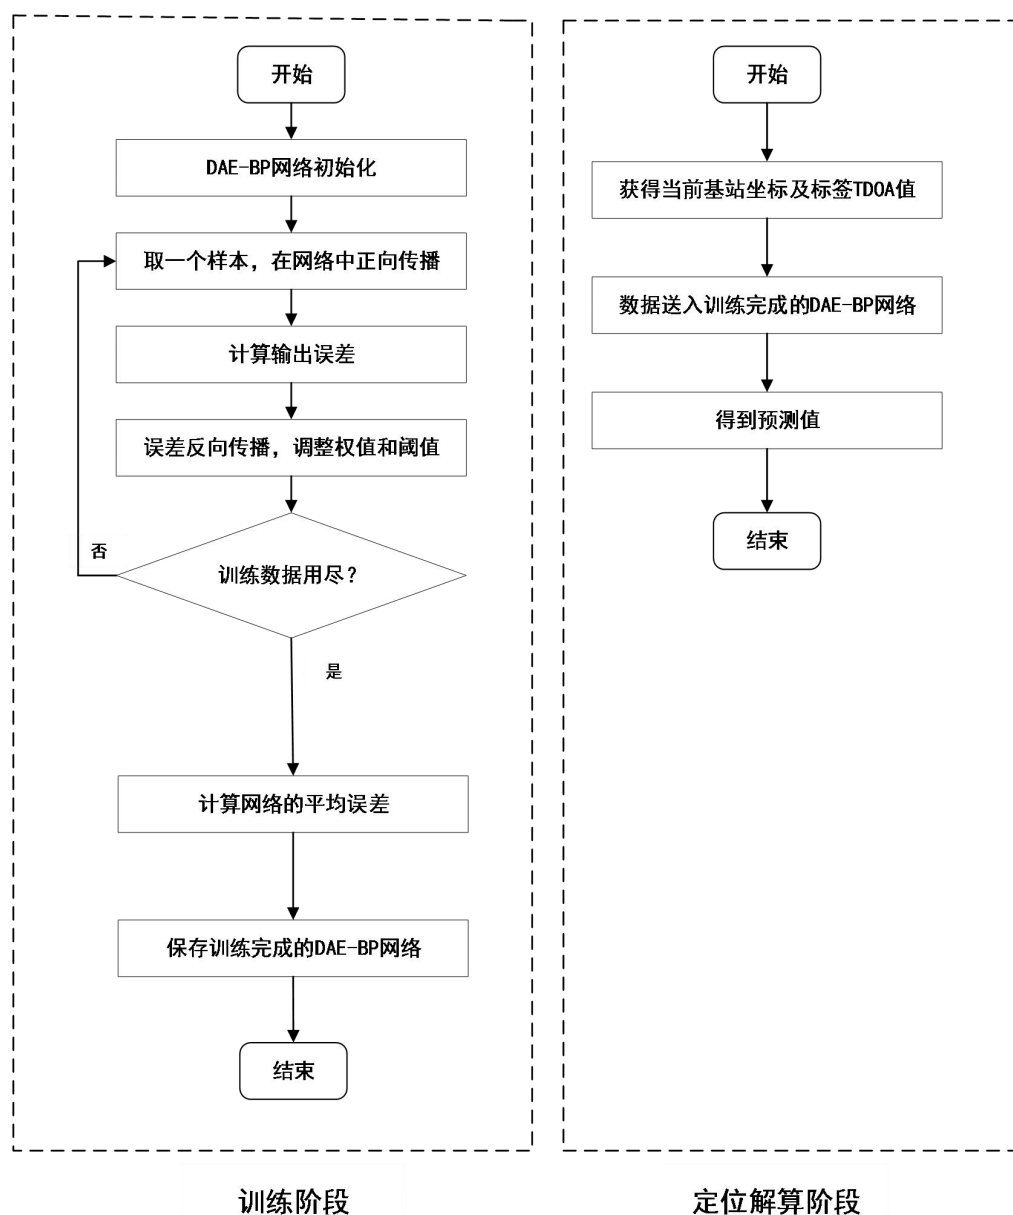


图 3.7 DAE-BP 网络训练与定位解算

Fig.3.7 Schematic diagram of DAE-BP

在网络模型训练阶段, 先取一个样本数据 (包括四个基站坐标值和 4 个 TDOA 值, 共 16 个数据元素) 进行网络正向传输, 计算误差, 误差反向调整各神经元权值, 下一个样本数据重复上述过程直到数据用尽, 保存网络结构及参数, 计算平均误差值。在定位解算阶段, 将新的 TDOA 数据及基站坐标输入训练完成的 DEA-BP 模型中, 得到预测位置坐标。

3.4.4 结果与分析

经过大量反复实验可以得到, 使用本文提出的 DAE-BP 网络经过训练后测试得到的

平均误差为 0.031，最大误差为 0.12，最小误差为 0.00003，如下（表 3.3）所示。对比 BP 神经网络和 DBN 网络的平均误差、最大误差和最小误差综合来看，深度自编码器与 BP 结合的网络结构在平均误差和最大误差两项表现最好，虽然最小误差较 BP 稍大，但整体上性能更佳。由此可知深度自编码器与 BP 神经网络相结合的网络结构以及网络参数设置使得预测误差较小，稳定性较高。

表 3.3 均方误差比较表

Tab.3.3 Mean Squared Error Comparison Table

所用神经网络	平均误差	最大误差	最小误差
DAE-BP	0.031	0.12	0.00003
BP	0.037	0.17	0.00001
DBN	0.042	0.19	0.00005

本实验的对照组为 BP 神经网络和深度置信网络（DBN）。三种网络结构在测试数据集中的均方误差分布如下（图 3.8）所示。三条曲线都是呈现上下波动的走势，其中蓝色线条即本文所提 DAE-BP 模型，其在误差波动幅度和峰值两方面在三种网络结构中表现最佳。BP 和 DBN 的误差即图中红线和橙线所示，在前半部分 BP 的误差高峰值最大，DBN 的低谷值较小，在后半部分 DBN 的误差高峰值最大，BP 的低谷值较小。而 DAE-BP 一直处于高峰和低谷值之间，波动较为平稳。



图 3.8 均方误差比较图

Fig.3.8 Mean Squared Error Comparison Chart

对于 BP 神经网络来说弊端在于易陷入局部极小值，还会出现收敛缓慢，甚至不收

敛的情况，所以平均误差较大，误差的波动也相对较大。

对于 DBN，它由受限玻尔兹曼机 (RBM) 和 BP 组成^[59]。采用训练好一个将其固定再训练下一个的方式，依次训练 3 个 RBM。随后，数据进入一个三层的 BP 神经网络。DBN 结构复杂，参数较多，计算复杂度较高，想要模型效果好较困难。实验中网络设置参照本文所提 DAE-BP，均方误差作为损失函数进行计算，使用 Adam 进行寻优，学习率为 0.001。在这种神经网络设置下测试误差（平均均方误差）在 0.042 左右。

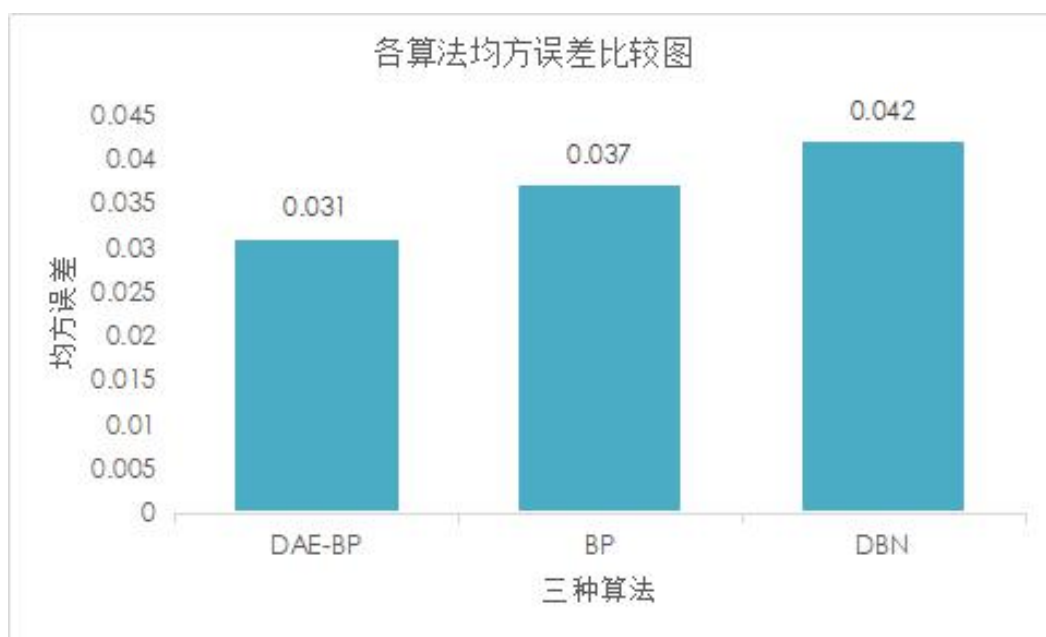


图 3.9 平均均方误差比较图

Fig.3.9 Mean Mean Squared Error Comparison Chart

经过上(图 3.8)和(图 3.9)误差对比可知，深度自编码器结合 BP 神经网络(DAE-BP)这种结构的神经网络测试效果较 BP 与 DBN 这两种神经网络误差更小，稳定性更高，整体效果更好。

本实验利用 UWB 设备在实验室的环境下测得数据，利用一个 6 层的深度自编码器结构对数据进行预处理，使得 UWB 信号的 TDOA 值在缺失或是受多径效应等因素影响时能够得到弥补和纠正。数据预处理后进入 5 层的 BP 神经网络，最后对该结构进行测试。本文利用 DAE-BP、BP 及 DBN 三种不同结构进行对比实验，通过比较得到本文提出的 DAE-BP 能够在本实验数据集这种数据组织形式下表现出误差更小，稳定性更高的良好性能。

3.5 本章小结

本章内容主要介绍本文提出的基于深度自编码器的定位方法，对该模型的框架结构做了详细阐释，并对其原理和原因做了解释说明，同时也较为细致的讲述了所提出的网络模型的数据训练过程。并且与其他神经网络定位情况做了对比实验，并对原因作出分析。

在本章的第二部分介绍了人工神经网络的通用结构和特点，然后就本文涉及的几种类型的神经网络进行了详细的介绍，包括自编码器、BP 和 CNN。

在本章的第三部分给出了评价模型定位性能好坏的依据。本文使用均方根误差和欧氏距离。其中均方根误差在本章基于深度自编码器的定位和第四章基于注意力机制的定位中用到，均方根误差以及欧式距离在第四章本文的第二个定位实验中用到。

第 4 章 基于注意力机制的 UWB 定位算法

4.1 引言

考虑到在动态因素干扰的环境中,希望未受到动态干扰影响或是受到影响较小的那部分数据获得更多关注,而这一点与注意力机制的作用相吻合,所以采用注意力机制来实现这一过程。本章提出一种基于注意力机制的 UWB 定位算法。由 SENet 注意力模块与卷积神经网络构建一个深度学习网络 SE-CNN。SENet 注意力模块降低了受到动态干扰因素影响的定位数据权重,再利用卷积神经网络(CNN)确定定位数据与目标位置的非线性关系。该定位模型能够减少动态环境下多径效应与非视距带来的定位误差。实验结果表明,该算法在定位精度方面优于其他算法,且具有较好的稳定性。

4.2 注意力机制概述

注意力机制目前正处于飞跃发展阶段。它是从人类观察和获取外界信息的方式中得到启示,并发明的一种独特的处理信息的方式。通过实验验证了它对于网络模型表达能力的提升有着不可忽视的作用。

之所以命名为注意力机制,是类比人类专注某部分事物的行为,注意力机制是一种关注某部分信息的机制。就像是观察一幅人物画时,更关注人本身,而非人身后的背景。注意力机制旨在寻找和关注规定的“感兴趣”部分的信息,它本身是灵活变化的。

从根本上讲,注意力机制就是找到感兴趣的部分,忽视不感兴趣部分的信息。概率特征向量和概率图是该机制作用的呈现方式。下面对具有代表性的注意力机制进行简要介绍^[60]。

4.2.1 通道注意力机制

这里,我们以典型的空间注意力模型 SEnet (Squeeze-and-Excitation Network) 为例进行阐述说明,该模型曾在 ImageNet 分类比赛中夺魁。

SEnet 的作用是自学习得到各特征通道重要性,给通道加权,以便自动增强关注的特征、降低非关注的特征。该模型包括两大模块,一是 Squeeze 压缩模块,二是 Excitation 激励模块^[61]。下面详细介绍两模块的作用。

压缩操作即压缩空间维度。是对每组特征数据做全局平均池化,得到一个平均的实数值^[62]。

激励操作是在上一步压缩操作后,它利用 w 给每个通道学习生成权重值, w 权重值表达的是特征通道之间的关联性。实践操作中,这一过程可以用卷积层或者全连接层构建完成。使用卷积层的较多,有利之处在于可以提高模型的非线性映射能力,还能够削减模型的运算规模。在这之后,激励操作的输出被视为进行特征选择过的各个通道的重要程度,接着采用乘法加权将该输出与之前的输入相乘,以达到增强重要特征和减弱非关注特征的效果。

总体来看,该过程是数据通过 Global Average Pooling 层,对每组特征数据做全局平均池化,可以得到平均的实数值。然后进入全连接层。特征通道权重表征通道间的相关性也即特征选择后每个通道的重要性,得到的各通道权重通过乘法再作用于原数据的各个通道上。从 SE block 输出的数据是在通道维度上对原数据重要程度进行重新标定过的数据,也即提高重要特征抑制非重要特征之后的数据。接着数据进入卷积层,完成特征提取,最后通过线性连接层输出。

通道注意力机制的思想在于对各个特征通道之间的重要程度进行建模,针对不同的目标能够依据输入数据完成特征分配,模型虽简作用却大。

4.2.2 空间注意力模型

空间注意力机制的代表本文选用 AA-Net (Attention-Augmented-Conv2d Network) 进行介绍。该模型在空间以及特征子空间同时加入注意机制。

AA-Net 模型引入更多的特征映射,目的是采取自注意力机制。该机制对输入数据进行矩阵运算可以得到注意力的权重分布,接着利用多次 Head 操作给若干空间定值,空间内部则进行点乘操作^[63]。

AA-Net 模型可以看作是三个网络的组合体。它们分别是全局特征网络 (Global Feature Network, GFN)、零件特征网络 (Part Feature Network, PFN)、属性特征网络 (Attribute Feature Network, AFN)^[64]。

GFN 的作用是使用全局特征完成 ID 分类操作。

PFN 的作用是关注某部分 part 检测,并对检测结果完成分类任务。全局 ID 分类器和 Part 分类器都采取全局平均池化的方式来降低过拟合。

AFN 的作用是由输入数据的属性中得到可以帮助划分类别的注意力区域,形成关于属性的注意图。

4.2.3 结合通道和空间的注意力模型

结合通道和空间注意力机制的代表本文选用 CBAM (Convolutional Block Attention Module) 进行介绍^[65]。

该模型中基于特征通道的这一想法与 3.1.1 中介绍的 SEnet 具有相似性,只是在 SEnet 的基础上又添加最大池化,并共享多层感知器。

其作用过程如下:

输入数据的特征图通过基于宽度和高度的池化,再进入共享的多层感知机^[66]。然后对数据完成加和运算后经过激活,得到的结果乘上原输入即为通道注意力模块的输出,为空间模块做准备。

上面得到的输出为输入。对其完成基于通道的池化操作,然后基于通道进行组合操作,随后卷积降维和函数激活,得到的结果乘上此模块输入即得到最终的输出。

4.3 注意力机制网络模型

本实验结合 SEnet 和 CNN 网络,构建了一种用于 UWB 定位的网络模型——SE-CNN。如(图 4.1)所示:




图 4.1 SE-CNN 模型图

Fig.4.1 SE-CNN model diagram

按照上图所示顺序，从左至右处理过程为：将预处理好的数据送入 SE block 模块，数据通过 Global Average Pooling 层，对每组特征数据做全局平均池化，可以得到一个平均的实数值。然后进入全连接层。通道权重表征通道间的相关性也即特征选择后每个通道的重要性，得到的各通道权重通过乘法再作用于原数据的各个通道上。从 SE block 输出的数据是在通道维度上对原数据重要程度进行重新标定过的数据，也即提高重要特征抑制非重要特征之后的数据。接着数据进入两个卷积层，完成特征提取，最后数据进入神经元数量为 32 和 2 的线性连接层。模型输出与真实值的差反向回传到网络中调整各部分的参数值，直到训练数据用尽。

网络模型按照功能分为以下四块：

输入模块：输入的是四个基站的坐标以及四个 TDOA 值。数据组织形式表示如下：

$$\begin{cases} (X_n, Y_n) (BS_1, BS_2, BS_3, BS_4, TDOA_n) \\ TDOA_n = [TDOA_{13}^{ni}, TDOA_{23}^{ni}, TDOA_{33}^{ni}, TDOA_{43}^{ni}] \end{cases}$$

其中， (X_n, Y_n) 表示第 n 个定位点， BS_{1-4} 表示 4 个基站坐标， $TDOA_{13}^{ni}$ 表示第 n 个定位点的主基站 3 与从基站 1 间的第 i 个 TDOA 值，其它的以此类推。

通道注意力模块：利用 SENet 模块。数据通过 Global Average Pooling 层，对每组数据做池化，然后进入两层全连接层。通道权重表征特征选择后每个通道的关注程度，得到的权重通过乘法再作用于原数据的各个通道上。SENet 的公式推导如下式所示：

$$z = F_{sq}(u_c) = \frac{1}{W \times H} \sum_{i=1}^W \sum_{j=1}^H u_c(i, j) \quad (4-1)$$

$$s = F_{ex}(z, W) = \sigma(g(z, W)) = \sigma(W_2 \delta(W_1, z)) \quad (4-2)$$

$$x_c = F_{scale}(u_c, s) = s_c \bullet u_c \quad (4-3)$$

式中： u_c 为特征通道， W_1 、 W_2 为全连接层权重值， $\delta(\)$ 和 $\sigma(\)$ 分别表示 Relu 和 sigmoid 函数。

从 SENet 输出的数据是在通道维度上对原数据重要程度进行重新标定过的数据。

特征提取模块：包含两个卷积层和两个线性连接层。从 SENet 模块输出的数据分别经过两次卷积操作和最大池化操作提取特征。最后数据进入神经元数量为 32 和 2 的线性连接层。

输出模块：输出为估计位置。

如上（图 4.1）所示的模型是由一个 SENet 模块，2 个卷积层、2 个池化层和 2 个全连接层组成。SE-CNN 网络参数：（1）激活函数为 Relu；（2）优化器为 Adam；（3）学习率设置为 0.001；其具体的各层参数如下（表 4.1）所示。

表 4.1 SE-CNN 参数表

Tab.4.1 SE-CNN parameter table

网络层	卷积核尺寸	该层输出数据形态
SENet	—	(16, 16)
conv1	(4, 4)	(16, 16, 5, 5)
pool1	2	(16, 16, 2, 2)
conv2	(4, 4)	(16, 32, 3, 3)
pool2	2	(16, 32, 1, 1)
fc1	—	(16, 32)
fc2	—	(16, 2)

4.4 数据准备

本实验中，训练和测试数据均来源于各基站进行时钟同步之后，收到的标签发送的定位信号，并经过进一步处理得到的 TDOA 值。将得到的数据按 7:3 的比例划分训练和测试集。模型的输入本文利用的是 4 个基站的坐标和多组 TDOA 值。定位模型的输出为目标位置，用 X 和 Y 两维坐标表示。红外测距仪测得的标签的真实坐标，用来计算模型输出目标位置与真实坐标的误差 这里的单位都是米。将标签固定在高度为 1 米的位置，可以先将三维问题转化成二维问题，所以模型的输出只考虑 X 和 Y 两个。部分数据如下（图 4.2）所示。

基站1 (从)			基站2 (从)			基站3 (主)			基站4 (从)			TDOA值				标签真实坐标		
X	Y	Z	X	Y	Z	X	Y	Z	X	Y	Z	1-3	2-3	3-3	4-3	X	Y	Z
22.302	3.555	2.868	15.24	3.555	2.868	21.905	7.731	2.909	15.382	7.731	2.868	-2.123809	1.1338293	0	1.7830971	20.702	3.555	1
22.302	3.555	2.868	15.24	3.555	2.868	21.905	7.731	2.909	15.382	7.731	2.868	-2.077092	1.2485024	0	1.8842315	20.702	3.555	1
22.302	3.555	2.868	15.24	3.555	2.868	21.905	7.731	2.909	15.382	7.731	2.868	-2.139186	1.1849172	0	1.851934	20.702	3.555	1
22.302	3.555	2.868	15.24	3.555	2.868	21.905	7.731	2.909	15.382	7.731	2.868	-2.189495	0.9637189	0	1.9026933	20.702	3.555	1
22.302	3.555	2.868	15.24	3.555	2.868	21.905	7.731	2.909	15.382	7.731	2.868	-2.217323	1.1710659	0	1.8819633	20.702	3.555	1
22.302	3.555	2.868	15.24	3.555	2.868	21.905	7.731	2.909	15.382	7.731	2.868	-2.337638	1.1502569	0	1.8416448	20.702	3.555	1
22.302	3.555	2.868	15.24	3.555	2.868	21.905	7.731	2.909	15.382	7.731	2.868	-2.146837	1.1318352	0	1.7674894	20.702	3.555	1
22.302	3.555	2.868	15.24	3.555	2.868	21.905	7.731	2.909	15.382	7.731	2.868	-2.251889	1.2001678	0	1.9188393	20.702	3.555	1
22.302	3.555	2.868	15.24	3.555	2.868	21.905	7.731	2.909	15.382	7.731	2.868	-2.125013	1.2470861	0	1.8101732	20.702	3.555	1

图 4.2 部分实验数据展示图

Fig.4.2 Some experimental data display diagrams

因为如果量纲不同，直接放入模型进行训练会对模型的准确性和普适性造成影响，所以需要对数据进行统一的规范化处理。数据标准化(normalization)的作用是将数据投射到某个小的指定区域上。该方法通常用来突破单位和量纲局限，使不同量纲的数据得到统一比较。归一化属于数据标准化。下面介绍两种经常使用的归一化方式。

min-max 方法使数据投影在区间[0,1]内，它的转换函数为 $x^* = \frac{x - \min}{\max - \min}$ 其中 max 表示数据集中最大的值，min 表示最小的值。该方法的弊端在于数据集发生增删操作时，max 以及 min 的值需要重新确定。

本实验用的是 Z-score 标准化。该方法使用整体的平均值和标准差完成归一化操作。数据经过 Z-score 法之后，呈现正态分布，该方法的转换函数为： $x^* = \frac{x - \mu}{\sigma}$ ，其中 μ 为所有数据的平均值， σ 为所有数据的标准差。归一化后数据准备完成。

4.5 定位过程

基于自建数据集的 SE-CNN 定位算法的训练过程如下：

(1) 训练网络生成定位模型阶段：

Step1: 初始化 SE-CNN 网络中的权值及阈值；

Step2: 从数据集中取一批训练样本，每批训练样本包含 16 条数据，每条数据中包括 4 个基站各自的坐标、4 个 TDOA 值以及标签所在的参考点位置坐标，取每条数据的前 16 个元素作为网络的输入，逐层传输，并计算输出与参考点位置坐标之间的误差。误差的计算使用 MSELoss 函数，最终使用平均 MSELoss 作为判断定位结果优劣的标准；

Step3: 误差在网络中反向传播。利用 MSELoss 函数得到误差，再将其返回，并计算出每一层的误差，最后权值得以更新。这一过程的目的是通过训练样本调整网络参数值；

Step4: 重复步骤 2-3 直到网络输出与参考点位置坐标的误差达到要求为止。

网络训练结束后，保存训练完成的 SE-CNN 网络模型及参数，用于定位解算阶段的目标定位。

(2) 定位解算阶段：

Step1: 将标签放置到已知位置的测试点，服务器已存储各基站坐标，并实时计算 TDOA 值；

Step2: 将定位数据输入定位模型, 即可得到标签的估计位置。

训练网络及定位解算过程的流程图如(图 4.3)所示。

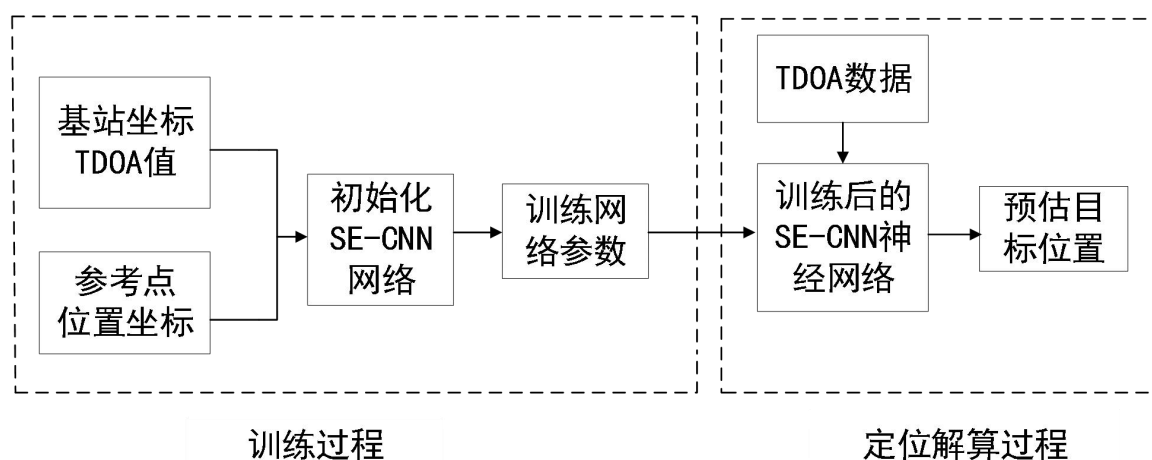


图 4.3 SE-CNN 网络训练与定位解算

Fig.4.3 SE-CNN network training and localization solution

4.6 结果分析

本文使用均方误差和欧氏距离作为评价指标来比较各个算法的性能。由下(表 4.2)中各算法的误差比较可以看出, 本文提出的 SE-CNN 网络得到的平均误差为 0.0012, 在实验的所有神经网络中误差最小, 且最大误差与最小误差相差最小, 定位稳定性相对较高。

表 4.2 不同定位算法均方误差比较

Tab.4.2 Comparison of Mean Square Error of Different Positioning Algorithms

所用神经网络	平均误差	最大误差	最小误差
SE-CNN	0.0012	0.050	0.000002
BP	0.037	0.17	0.000030
DAE-BP	0.031	0.12	0.000030
CNN	0.0014	0.17	0.000003
DBN	0.035	0.15	0.000050

为了让定位结果有更为具体的效果对比,也将各种算法的定位结果进行了欧氏距离的求解,求解原理上文 3.3 中有具体说明。下(图 4.4)中利用柱状图呈现 4 种算法欧氏距离测试均值,单位为米。(图 4.4)中可以明显看出本文提出的 SE-CNN 与 CNN 网络表现突出,SE-CNN 的平均均方误差在 25cm,CNN 的平均均方误差为 28cm.




图 4.4 各算法平均欧式距离比较图

Fig.4.4 Comparison of the average Euclidean distance of each algorithm

为了进一步分析 SE-CNN 与 CNN 的性能表现,这里给出两种模型在测试样本集中的具体数值的走势图,如下(图 4.5)所示。



图 4.5 SENet 与 CNN 欧式距离分布图

Fig.4.5 SENet、CNN Euclidean distance distribution map

从(图 4.5)中可以看出,在样本数据的前半段 SE-CNN 模型的欧氏距离误差与 CNN 模型部分重合,差别较小,但在后半段的样本数据中 SE-CNN 的误差值明显低于 CNN 模

型, 并且 CNN 模型会出现个别点误差极大地情况。原因在于环境中出现动态的人或物时, CNN 模型对突然变化的信号无法进行选择, 而 SE-CNN 模型可以对通道权重进行自动选择, 所以定位结果较 CNN 模型表现更好。

用同样的方法得到 4 种算法各自的误差分布图, 如 (图 4.6) 所示。




图 4.6 各算法欧式距离分布图

Fig.4.6 Euclidean distance distribution diagram of each algorithm

针对上图定位结果以及各模型特性, 作出如下分析:

BP 神经网络极易陷入局部极小值, 所以平均误差较大, 误差的波动也相对较大。CNN 网络对受干扰的定位数据敏感, 因此误差会有跳变到很大的情况, 定位误差不稳定。深度置信网络 (DBN) 结构复杂, 计算复杂度较高, 学习过程较慢, 容易收敛于局部最优解, 所以最小误差较大, 平均误差相对较大。

本文利用通道注意力特性, 结合 CNN 构建了一个深度学习网络 (SE-CNN), 设计了一种基于注意力机制的室内定位算法。以 UWB 的 TDOA 值作为研究对象, 利用基站位置、TDOA 值组成的定位数据与 TDOA 值对应的真实位置对 SE-CNN 进行训练。先使用基于通道注意力机制的 SENet 模块, 使得在无动态干扰影响下的 TDOA 通道获得较大权重值, 受到动态因素环境干扰的 TDOA 数据通道获得较小权重值, 以减少 TDOA 测量值中因动态干扰因素引起的 NLOS 以及多径所产生的误差, 接着利用 CNN 网络的映射能力建立定位数据与目标位置之更准确的非线性关系, 得到较优的定位模型。综上所述, 本文提出的算法定位精度优于其它算法, 且稳定性好。

4.7 本章小结

本章内容围绕基于注意力机制的 UWB 定位算法展开。

在本章的开头首先对注意力机制进行了阐述, 分别简要介绍了基于通道、基于空间和基于通道结合空间的注意力模型。

接着进入实验部分，首先介绍实验环境以及所用设备和部署情况，接着说明实验数据预处理过程，包括数据集结构和标准化方法。然后详细阐释了本文提出的 SE-CNN 模型的结构和功能，以及参数设置。之后分步说明模型的具体定位步骤，最后根据实验数据结果将本文提出的模型与其他神经网络模型进行对比分析，所提网络模型利用通道注意力机制，增大无动态干扰影响下的 TDOA 通道权重值，减少受到动态因素环境干扰的 TDOA 数据权重值，降低移动的人或物等动态干扰因素对定位性能的影响，减少多径效应和 NLOS 带来的误差。对比证明本文提出的算法定位效果较好。

第 5 章 结论与展望

5.1 结论

本文的研究重点围绕基于深度学习的 UWB 定位方法展开。研究对象是基站位置数据与 TDOA 值。针对影响定位结果的因素进行了探索和思考，给出了消减影响的创新模型。

针对室内定位 UWB 技术存在因非视距、多径效应等影响造成的定位结果稳定性差，精确度低的问题，本文第三章提出一种基于深度自编码器的定位模型 DAE-BP，该模型利用一个 6 层的深度自编码器结构对数据进行预处理，使得 UWB 信号的 TDOA 值在缺失或是受多径效应等因素影响时能够得到弥补和纠正。数据预处理后进入一个 5 层的 BP 神经网络建立映射。该模型在本文建立的数据集中表现出较好的性能。

出于现实场景下，会有动态的人或物移动情况的考虑，本文第四章在基于通道注意力的启发下，提出一种适用于有动态搅扰因素环境下的基于注意力机制的 UWB 定位模型，该模型利用基站位置、TDOA 值组成的定位数据与 TDOA 值对应的真实位置对 SE-CNN 进行训练。将该网络模型训练后生成的定位模型利用通道注意力机制，使得在无动态干扰影响下的 TDOA 通道获得较大权重值，受到动态因素环境干扰的 TDOA 数据通道获得较小权重值，削弱了移动的人或物等动态干扰因素对定位性能的影响，减少了多径效应与 NLOS 环境的误差，提高精度及稳定性，在真实的应用场景中具有良好的适应性。

5.2 展望

经过本文实验，验证了深度学习在室内 UWB 定位中的有效性。为了进一步提高定位精确度，还需对 UWB 定位数据与神经网络模型的结合进行思考。下一步研究计划如下。

第一个计划已经有了雏形。在实验中意识到的一个问题是，在一间实验室内实验，那么所有的基站位置坐标是不变的，发生变化的只是 TDOA 值，这也造成了数据冗余。之所以要加入基站位置坐标，是因为实验开始时的设想是实现一个楼层的多间实验室以及走廊的定位。出于这一点考虑，可以在 SE-CNN 的基础上再加入空间注意力机制，使得现阶段的单个实验室的 UWB 定位中更关注 TDOA 数据而非基站坐标。

具体设想如下：

由于实验室场景下会有不确定的移动因素干扰定位结果，以及在同一间实验室内基站的位置坐标不变，也就是输入的前 12 个元素不变，变化的是 4 个 TDOA 值，所以更应该关注没有被移动因素干扰的通道，以及变化的 4 个 TDOA 值。

所以利用 CBAM 模块的通道注意力和空间注意力性能，完成将更大的权重赋给未受移动因素干扰的通道和每条数据的第 13-16 位，也即 TDOA 值所在位置。

归一化后的数据作为 CBAM-CNN 网络输入，数据先进入 CBAM 模块，该模块在本文 4.2 中已有论述。在通道注意力模块中，输入数据经过并行的平均池化和最大池化操作压缩维度后进入共享的多层感知器，再经过激活之后输出。接着，通过卷积、激活得到卷积网络的输入，再经过多个卷积层和线性连接层即可得到最终的模型输出。

训练阶段具体流程如下。

第一步：初始化 CBAM-CNN 的权值及阈值。

第二步：批训练的方式进行模型训练，每批训练数据包含 16 条数据，每条数据包括基站坐标、TDOA 值、标签真实位置坐标，按照步骤一中所述，前 16 个元素输入模型，逐模块传送数据，并计算模型输出与真实坐标间的差值。差值利用 MSELoss 函数计算得出。模型的性能评价指标，本发明利用的均方误差函数进行计算。

第三步：差值在模型中反向传播，调整模型中的权值和阈值。利用 MSELoss 函数计算差值，逐层调整更新权重及偏置。

第四步：判断定位数据是否都已训练，若否，则回步骤二执行；若是则完成训练，计算模型误差，保存训练后的 CBAM-CNN 模型，待在线测试时加载使用。

若模型表现不理想，误差偏大，则考虑步长的调整和优化器的更换。

测试阶段具体流程如下。

第一步：通过定位服务器得到新的定位数据并进行预处理。

第二步：加载训练后的 CBAM-CNN 模型。

第三步：将预处理后的定位数据输入模型中得到标签的预测位置坐标。

第二个计划是针对优化器的考虑。本文的两个实验包括基于深度自编码器的定位实验和基于注意力机制的定位实验中，神经网络所用的优化器都是 Adam。该优化器较为常用，它是一种自适应学习率的方法。不足之处在于更新梯度时，可能会得到较大的参数值，并且学习率与权重无法单独进行调试。所以希望利用性能更优，与数据集更适配的寻优算法代替 Adam 优化器，完成权值与阈值的更新。在文献的查找和阅读过程中发现天牛须搜索算法和麻雀搜索算法具有原理清晰简单，寻优效果较好的特点，所以下一步实验，打算用这两个算法替代 Adam 优化器进行测试。

第三个预想是对目前实验场景的考虑。目前的实验环境是实验室的环境，人员移动和物体的移动较少，场景单一。下一步计划将在物流仓库、工厂等动态复杂的定位场景下验证并改进本文定位模型的性能。

深度学习领域深如海洋，且发展势头迅猛，我所看到的、学习到的只是冰山一角，UWB 定位的难题仍需要进一步的分析和解决。更好更优的定位方法我相信一定存在，或许会随着深度学习领域和 UWB 技术的发展逐步涌现，当然随之而来的可能有很多新的问题，这都是值得期待的。

参考文献

- [1] 刘成. LBS 定位技术研究与发展现状[J]. 导航定位学报, 2013, 1(01):78-83.
- [2] Paul Groves, Principles of GNSS, Inertial, and Multisensor Integrated Navigation Systems, Second Edition, Artech, 2013.
- [3] H. X. Jian and W. Hao, WIFI Indoor Location Optimization Method Based on Position Fingerprint Algorithm, 2017 International Conference on Smart Grid and Electrical Automation (ICSGEA), Changsha, 2017, pp. 585-588.
- [4] 刘明伟, 刘太君, 叶焱, 吴丽. 基于低功耗蓝牙技术的室内定位应用研究[J]. 无线通信技术, 2015, 24(03):19-23.
- [5] 肖竹, 王勇超, 田斌, 于全, 易克初. 超宽带定位研究与应用:回顾和展望[J]. 电子学报, 2011, 39(01):133-141.
- [6] 刘关迪, 赵璐. 基于 UWB 技术的室内智能跟随系统的实现与优化[J]. 计算机应用与软件, 2020, 37(12):95-100.
- [7] R. Carotenuto, M. Merenda, D. Iero and F. G. Della Corte, An Indoor Ultrasonic System for Autonomous 3-D Positioning, in IEEE Transactions on Instrumentation and Measurement, 2019, vol. 68, no. 7, pp. 2507-2518.
- [8] 谢正威. 基于惯性导航的行人室内定位研究[D]. 燕山大学, 2020.
- [9] Alsindi N , Duan C , Zhang J , et al. NLOS channel identification and mitigation in Ultra Wide band ToA-based Wireless Sensor Networks[C]. Workshop on Positioning, Navigation & Communication. IEEE, 2009.
- [10] D. Dardari, A. Conti. Bandwidth Signals in 404-426 U. Ferner, A. Giorgetti and M. Z. Win, Ranging With Ultrawide Multipath Environments[J]. Proceedings of the IEEE, 2009, 97(2).
- [11] A. Cazzorla, G. De Angelis, A. Moschitta, M. Dionigi, F. Alimenti and P. Carbone, A 5.6-GHz UWB Position Measurement System[J]. IEEE Transactions on Instrumentation and Measurement, 2013, 62(3):675-683.
- [12] Fontana R J , Foster L A , Fair B , et al. Recent Advances in Ultra Wideband Radar and Ranging Systems[C]. IEEE International Conference on Ultra-wideband. IEEE 2007.
- [13] F. Ramirez-Mireles, Performance of UWB Orthogonal PPM in AWGN and Multipath Channels, in IEEE Transactions on Vehicular Technology, 2007, 56(3):1272-1285.
- [14] A. Nasri, R. Schober and L. Lampe, Performance of BICM-OFDM systems in

- UWB interference, in IEEE Transactions on Wireless Communications, 2009, 8(9):4389-4392.
- [15] L. Liu and G. Fang, A Novel UWB Sampling Receiver and Its Applications for Impulse GPR Systems, in IEEE Geoscience and Remote Sensing Letters, 2010, 7(4):690-693.
- [16] Y. Sadi and S. C. Ergen, Fast Scheduling for Delay Minimization in UWB Wireless Networks, in IEEE Communications Letters, 2012, 16(9):1400-1403.
- [17] H. Xiong, W. Zhang, Z. Du, B. He and D. Yuan, Front-End Narrowband Interference Mitigation for DS-UWB Receiver, in IEEE Transactions on Wireless Communications, 2013, 12(9):4328-4337.
- [18] B. Hanssens, An Indoor Variance-Based Localization Technique Utilizing the UWB Estimation of Geometrical Propagation Parameters, in IEEE Transactions on Antennas and Propagation, 2018, 66(5):2522-2533.
- [19] J. Zhu and S. S. Kia, Bias Compensation for UWB Ranging for Pedestrian Geolocation Applications, in IEEE Sensors Letters, 2019, 3(9):1-4.
- [20] S. Gao and K. Moez, A 2.12-V $V_{pp} \sim 11.67$ mV/pulse Fully Integrated UWB Pulse Generator in 65-nm CMOS Technology, in IEEE Transactions on Circuits and Systems I: Regular Papers, 2020, 67(3):1058-1068.
- [21] Y. Cao, C. Chen, D. St-Onge and G. Beltrame, Distributed TDMA for Mobile UWB Network Localization, in IEEE Internet of Things Journal, 2021, 8(17):13449-13464.
- [22] 罗勃. 基于 UWB 技术的 TDOA 定位算法的研究与实现[D]. 海南大学, 2017.
- [23] 杨天池, 金梁, 程娟. 一种基于 TOA 定位的 CHAN 改进算法[J]. 电子学报, 2009, 37(04):819-822.
- [24] 祖明浩, 荣宪伟. 基于内三角形质心修正-Taylor 的 UWB 室内定位算法[J]. 哈尔滨师范大学自然科学学报, 2018, 34(06):42-47.
- [25] 仲江涛, 秦斌, 吴健春, 刘童. 基于 Kalman 滤波的 Chan 室内定位算法改进[J]. 通信技术, 2017, 50(10):2223-2228.
- [26] 曾玲, 彭程, 刘恒. 基于信号到达时间差的超宽带室内定位算法[J]. 计算机应用, 2018, 38(S1):135-139.
- [27] 王磊, 李鹏涛, 贾宗璞. 基于全质心-Taylor 的 UWB 室内定位算法[J]. 传感器与微系统, 2017, 36(06):146-149.
- [28] 孙顶明. 基于 CHAN-Taylor 的室内复杂环境 UWB 定位算法研究[D]. 南京邮电大学, 2019.
- [29] 陈思翰. 基于 Fang 算法的 TDOA 室内定位技术[J]. 太赫兹科学与电子信息学

- 报, 2017, 15(05):752-755.
- [30] Y. Chen, S. Huang, T. Wu, W. Tsai, C. Liou and S. Mao, UWB System for Indoor Positioning and Tracking With Arbitrary Target Orientation, Optimal Anchor Location, and Adaptive NLOS Mitigation[J]. Transactions on Vehicular Technology, 2020, 69(9):304-9314
- [31] J. B. Kristensen, M. Massanet Ginard, O. K. Jensen and M. Shen, Non-Line-of-Sight Identification for UWB Indoor Positioning Systems using Support Vector Machines, 2019 IEEE MTT-S International Wireless Symposium (IWS), 2019, pp. 1-3.
- [32] Z. Zhao, W. Huang, Y. Liang and Y. Zhang, A NLOS Detection Method Based on Machine Learning in UWB Indoor Location System, 2020 International Conference on Virtual Reality and Intelligent Systems (ICVRIS), 2020, pp. 214-217.
- [33] H. Wang, X. Wang, Y. Xue and Y. Jiang, UWB-based Indoor Localization Using a Hybrid WKNN-LSTM Algorithm, 2020 IEEE 4th Information Technology, Networking, Electronic and Automation Control Conference (ITNEC), 2020, pp. 1720-1725.
- [34] 孙晔, 肖竹, 李小蓓, 向新. UWB 定位中基于神经网络的 TDOA 解算方法[J]. 航空计算技术, 2019, 49(02):6-10.
- [35] 张宝军, 田奇, 王珩, 陈曦. 基于 CNN 和在线学习的 UWB 室内定位算法[J]. 传感技术学报, 2020, 33(04):511-516.
- [36] 李勇, 柳建. 基于 IA-BP 神经网络的 UWB 室内定位系统[J]. 电子测量技术, 2019, 42(05):109-112.
- [37] R. Bao and Z. Yang, CNN-Based Regional People Counting Algorithm Exploiting Multi-Scale Range-Time Maps With an IR-UWB Radar, in IEEE Sensors Journal, 2021, 21(12):137045-13713.
- [38] M. A. G. Al-Sadoon, R. Asif, Y. I. A. Al-Yasir, R. A. AOA Localization for Vehicle-Tracking Systems Using A bd-Alhameed and P. S. Excella Dual-Band Sensor Array[J]. IEEE Transactions on Antennas and Propagation, 2020, 68(8):6330-6345.
- [39] 方震, 赵湛, 郭鹏, 张玉国. 基于 RSSI 测距分析[J]. 传感技术学报, 2007(11):2526-2530.
- [40] 王昕, 王宗欣, 刘石. 一种考虑非视线传播影响的 TOA 定位算法[J]. 通信学报, 2001(03):1-8.
- [41] 朱永龙. 基于 UWB 的室内定位算法研究与应用[D]. 山东大学, 2014.
- [42] 孙胜, 李辉, 韩崇昭. 基于 TDOA 定位技术的仿真研究[J]. 无线通信技术, 2002,

- 11(4): 40-43.
- [43] 陆音, 王宝全, 丘勤玮. CHAN 算法在 LOS 和 NLOS 环境下的定位研究[J]. 计算机技术与发展, 2015, 25(09): 61-65.
- [44] F. Ramirez Mireles, Quantifying the Degradation of Combined MUI and Multipath Effects in Impulse-Radio UWB, in IEEE Transactions on Wireless Communications, 2007, 6(8): 2831-2836.
- [45] A. A. D'Amico, U. Mengali and L. Taponecco, Cramer-Rao Bound for Clock Drift in UWB Ranging Systems, in IEEE Wireless Communications Letters, 2019, 2(6): 591-594.
- [46] 赵甜甜. 基于时间的超宽带室内定位算法研究[D]. 华东师范大学, 2020.
- [47] 赵崇文. 人工神经网络综述[J]. 山西电子技术, 2020(03): 94-96.
- [48] Y. Xue, W. Su, H. Wang, D. Yang and Y. Jiang, DeepTAL: Deep Learning for TDOA-Based Asynchronous Localization Security With Measurement Error and Missing Data[J]. Access, 2019, 7(01): 122492-122502.
- [49] Z. Cui, Y. Gao, J. Hu, S. Tian and J. Cheng, LOS/NLOS Identification for Indoor UWB Positioning Based on Morlet Wavelet Transform and Convolutional Neural Networks, in IEEE Communications Letters, 2021, 25(3): 879-882.
- [50] 陈海, 钱付兰, 陈洁, 赵姝, 张燕平. 基于变分自编码器的评分预测模型[J/OL]. 计算机工程与应用, 2020(11): 1-10.
- [51] 虞晓芬, 傅玳. 多指标综合评价方法综述[J]. 统计与决策, 2004(11): 119-121.
- [52] J. Zhao, J. Dou and K. Ge, Application of LDHA-BP in Prediction of Atmospheric PM_{2.5} Concentration, 2019 IEEE 3rd Information Technology, Networking, Electronic and Automation Control Conference (ITNEC), Chengdu, China, 2019, pp. 2239-2245.
- [53] K. Yang, Research on UWB/IMU location fusion algorithm based on GA-BP neural network, 2021 40th Chinese Control Conference (CCC), 2021, pp. 8111-8116.
- [54] 李志, 赵大哲. 一种基于卷积神经网络的室内定位算法[J]. 小型微型计算机系统, 2019, 40(03): 533-537.
- [55] 张宝军, 田奇, 王珩, 陈曦. 基于 CNN 和在线学习的 UWB 室内定位算法[J]. 传感技术学报, 2020, 33(04): 511-516.
- [56] Z. Cui, Y. Gao, J. Hu, S. Tian and J. Cheng, LOS/NLOS Identification for Indoor UWB Positioning Based on Morlet Wavelet Transform and Convolutional Neural Networks, in IEEE Communications Letters, 2021, 25(3): 879-882.
- [57] 刘银恩. 高精度频率估计算法研究[D]. 南京理工大学, 2007.
- [58] 宋宇辰, 张玉英, 孟海东. 一种基于加权欧氏距离聚类方法的研究[J]. 计算机工程

- 与应用, 2007(04):179-186.
- [59] X. Zhang, F. Chung and S. Wang, An Interpretable Fuzzy DBN-Based Classifier for Indoor User Movement Prediction in Ambient Assisted Living Applications, in IEEE Transactions on Industrial Informatics, 2020, 16(1):42-53.
- [60] 王培森. 基于注意力机制的图像分类深度学习研究方法研究[D]. 中国科学技术大学, 2018.
- [61] J. Hu, L. Shen, S. Albanie, G. Sun and E. Wu, Squeeze-and-Excitation Networks[J]. Transactions on Pattern Analysis and Machine Intelligence, 2020, 42(8):2011-2023.
- [62] 刘学平, 李珣乾, 刘励, 王哲, 刘宇. 嵌入 SENet 结构的改进 YOLOV3 目标识别算法[J]. 计算机工程, 2019, 45(11):243-248.
- [63] Xu H., Zhang J. AANET: Adaptive aggregation network for efficient stereo matching[J]. Proceedings of the IEEE Computer Society Conference on Computer Vision and Pattern Recognition, 2020.
- [64] T. Bilen and B. Canberk, Learning-Vector-Quantization-Based Topology Sustainability for Clustered-AANETs, in IEEE Network, 2021, 35(4):120-128.
- [65] 赵红蕊, 薛雷. 基于 LSTM-CNN-CBAM 模型的股票预测研究[J]. 计算机工程与应用, 2021, 57(03):203-207.
- [66] Y. Luo and Z. Wang, An Improved ResNet Algorithm Based On CBAM, 2021 International Conference on Computer Network, Electronic and Automation (ICCNEA), 2021, pp. 121-125.

致 谢

三年的研究生生活已经进入尾声，回想起刚入学报道时的场景犹在昨日。这段时光没有发生什么轰轰烈烈的大事，但是点点滴滴、细细碎碎都是生动鲜活的，那些人和事都是值得在某个空闲的午后拿出来仔细回忆品味的。

我非常感谢我的导师张裕老师。张老师对学生一直都是认真负责的态度。从我刚入学起，就同我一起规划好了研究生期间需要完成的研究任务和时间节点，并且在过程中根据我的情况进度进行调整。在学术研究中，给我启发和引导，培养我解决问题的能力，让我逐步成长起来。张老师治学严谨的态度也深深影响我的科研和生活态度。我还记得，在期刊投稿前夕，张老师加班到深夜，逐句把关，帮我标注出需要改动和完善的地方。在关注我学术研究的同时，张老师也会细心关注我的生活状况，询问我是否遇到困难和不如意，也会给出宝贵意见。在这里，我想向张老师表达我真挚的感谢和崇敬之情，能够有幸成为您的学生我十分地高兴和感激。

我同样感谢我的父母，他们一直在我身后默默支持和鼓励我去见识更辽阔的天地，让我可以全身心地专注于学业和自己感兴趣的事情，没有后顾之忧，勇敢向前。

我非常感谢幸运之神的安排，让我遇到了一群热情真诚又个性鲜明的室友。李玲待人真诚，做事雷厉风行，因为她，我的拖延症几乎“痊愈”。张祺是个情感细腻的解语花，具有很强的上进心，因为她，我时常反思自己能不能更努力，可不可以做得更好。丁夏蕾聪明活泼，经常能给出看待和解决问题的全新视角，不是逐大流的泛泛之辈。因为她，我提醒自己保持独立思考的能力，面对问题不再激进，多了几分从容。我们在一起畅谈人生理想和未来规划时眼睛里光我一直记得。

我还想感谢我的师姐们，夏睿师姐自我开学以来就把我当做妹妹照顾，从课程用书到求职的资料都无保留地分享给我。还有王冬雨师姐和丁丹凤师姐，在我迷茫不知前路时，给我她们的过往经验，以及针对我个人的真知灼见。我由衷地感谢她们在我人生处于岔路口时给我的指引，让我能够走出彷徨，努力探寻自己的出路。

当然也要感谢实验室的小伙伴们，黄杰伦、何立君、胡雪琦等，和他们一起学习、实验，偶尔几个人也会组织一次小型茶话会，谈谈最近的学习进展和收获，他们意气风发的样子让我难忘。

纵然难舍，也到了必须要说再见的时候了。青山不改长词调，期年可把杯酒交。愿我们都能在自己的领域发光发热，期待再聚首的那天！

最后，我想向各位评审专家表达真诚的感谢。

攻读学位期间所开展的科研项目和发表的学术论文

- [1] 叶晓桐, 张裕, 宋俊典. 基于注意力机制的 UWB 室内定位算法[J]. 计算机应用与软件, 2021, 38(06):198-201.
- [2] X. Ye and Y. Zhang, Research on UWB positioning method based on deep learning, 2020 5th International Conference on Mechanical, Control and Computer Engineering (ICMCCE), 2020, pp. 1505-1508.
- [3] 张裕, 叶晓桐. 一种基于飞行器质心平衡的供油控制方法[P]. 中国专利: CN113501127A, 2021-10-18.
- [4] 张裕, 叶晓桐. 一种基于深度学习的 UWB 定位方法[P]. 中国专利: CN114364015A, 2022-4-15